

Relatório Final METABRIC

- [Expressão gênica, prognóstico e aprendizado de máquina no câncer de mama](#)
 - [Relatório final consolidado — coorte METABRIC \(n = 1.897\)](#)
 - [Sumário](#)
 - [1. Sumário executivo](#)
 - [2. Como ler os números](#)
 - [3. Dados, coorte e integridade](#)
 - [4. Métodos](#)
 - [5. Resultados — caracterização clínica e molecular](#)
 - [6. Resultados — genes associados à sobrevida](#)
 - [7. Resultados — aprendizado de máquina](#)
 - [8. Resultados — onde o modelo falha](#)
 - [9. Camada farmacogenômica](#)
 - [10. Plataforma de inferência](#)
 - [11. Erros cometidos e corrigidos](#)
 - [12. Limitações](#)
 - [13. Próximos passos](#)
 - [14. Inventário do pacote](#)
 - [15. Referências](#)

Expressão gênica, prognóstico e aprendizado de máquina no câncer de mama

Relatório final consolidado — coorte METABRIC (n = 1.897)

Instituição: Faculdade de Ciências Farmacêuticas, Universidade Federal do Amazonas **Coorte:** METABRIC — Curtis et al., *Nature* 2012; Pereira et al., *Nat Commun* 2016 **Dados:** METABRIC_RNA_Mutation.csv, MD5 c619471beb87af0f9fd4e4a40058654d **Ambiente:** R 4.3.3 (22 pacotes) e Python 3.12 (scikit-learn 1.8.0, lifelines 0.30.3, XGBoost 3.4.1) **Semente fixa 42** em todas as etapas aleatórias — todos os números deste relatório são reproduzíveis.

Sumário

- [1. Sumário executivo](#)
- [2. Como ler os números](#)
- [3. Dados, coorte e integridade](#)
- [4. Métodos](#)
- [5. Resultados — caracterização clínica e molecular](#)
- [6. Resultados — genes associados à sobrevida](#)
- [7. Resultados — aprendizado de máquina](#)
- [8. Resultados — onde o modelo falha](#)
- [9. Camada farmacogenômica](#)
- [10. Plataforma de inferência](#)
- [11. Erros cometidos e corrigidos](#)
- [12. Limitações](#)
- [13. Próximos passos](#)
- [14. Inventário do pacote](#)
- [15. Referências](#)

1. Sumário executivo

Este trabalho analisou 1.897 pacientes da coorte METABRIC combinando expressão de 489 genes, status mutacional de 173 genes e 31 variáveis clínicas, com três objetivos: identificar genes associados à sobrevida, comparar algoritmos de aprendizado de máquina para prever desfecho, e construir uma plataforma de inferência com limites de confiabilidade explícitos.

Os dez achados centrais:

- 125 genes associam-se à sobrevida global** (FDR < 0,05): 61 protetores e 64 de risco. Núcleo de pior prognóstico: *GSK3B*, *AURKA*, *VEGFA*, *FANCD2*. Núcleo de melhor prognóstico: *IGF1*, *STAT5A*, *SPRY2*, *CDKN2C*, *FLT3*, *ABCB1*.
- Três famílias metodológicas convergem** para o mesmo núcleo (*GSK3B*, *AURKA*, *STAT5A*, *FLT3*, *BCL2*): Cox univariado, seleção estável do LASSO em 25 repetições e importância do Random Forest — apesar de pressupostos radicalmente distintos.
- O sinal gênico é dependente do contexto.** No subtipo LumA, 12 de 12 genes testados são significativos; nos subtipos

Basal e Her2, **nenhum**. No estágio II, 71 genes; nos estágios I e III-IV, apenas um em cada. Um painel derivado da coorte inteira é, na prática, um painel para doença luminal.

4. **568 associações gene-subtipo** com assinaturas biologicamente coerentes, incluindo um controle positivo interno perfeito (*ERBB2* superexpresso exatamente no subtipo Her2).
5. **A classificação dos subtipos por expressão atinge 78,7% de acurácia** (Gradient Boosting), com erro concentrado entre pares biologicamente adjacentes.
6. **A maior falha do classificador é do rótulo, não do algoritmo**. O grupo “Normal-like” tem recall de 0,350, e o erro se associa à celularidade tumoral (FDR = 0,011) — não a grau, HER2, idade ou carga mutacional (todos FDR > 0,13).
7. **Dezesseis modelos preditivos foram treinados** (6 algoritmos × 3 conjuntos de variáveis) com busca de hiperparâmetros aninhada. O melhor é XGBoost sobre variáveis clínicas + expressão (AUC 0,749), mas seu intervalo de confiança se sobrepõe ao do segundo colocado.
8. **A expressão gênica isolada perde para 6 variáveis clínicas** em onze de onze algoritmos testados, todos com FDR < 0,003 e na mesma direção — o achado mais robusto do trabalho, precisamente por ser independente de escolha metodológica.
9. **A ordenação de risco funciona; a probabilidade absoluta exigia correção**. Os tercis de risco separam sobrevida mediana de 217,6 a 85,7 meses (log-rank $p = 1,8 \times 10^{-36}$), mas o modelo era grosseiramente descalibrado (Hosmer-Lemeshow $p = 5,7 \times 10^{-163}$) até a aplicação de regressão isotônica ajustada dentro da validação ($p = 0,66$ depois).
10. **Existe sinal farmacogenômico para hormonioterapia**: 14 genes modificam significativamente o efeito prognóstico conforme a paciente recebeu ou não bloqueio endócrino, e todos resistem ao ajuste por status de ER e subtipo molecular.

2. Como ler os números

Termo	Significado neste relatório
z-score de expressão	Expressão padronizada: 0 é a média da coorte, +1 é um desvio-padrão acima
HR (hazard ratio)	Risco relativo de óbito por +1 desvio-padrão de expressão. HR 1,20 = 20% mais risco; 0,80 = 20% menos
IC 95%	Faixa compatível com os dados. Se não cruza 1 (HR) ou 0,5 (AUC), o efeito é detectável
FDR	Valor-p corrigido para múltiplos testes (Benjamini-Hochberg)
Δz	Diferença de expressão média entre um subtipo e os demais, em desvios-padrão
AUC	Probabilidade de ordenar corretamente dois pacientes quanto ao risco. 0,5 = acaso
C-index	Análogo da AUC para dados de sobrevida censurados
Escore de Brier	Erro quadrático médio da probabilidade prevista. Menor é melhor
Hosmer-Lemeshow	Teste de calibração. p alto = boa calibração (ao contrário do usual)
OS / DSS	Sobrevida global (qualquer causa) / específica do câncer
Erro out-of-bag	Estimativa honesta de erro do Random Forest, com os casos que cada árvore não viu

3. Dados, coorte e integridade

Item	Valor
Pacientes no arquivo bruto	1.904
Coorte analítica	1.897
Colunas	693 (31 clínicas + 489 expressão + 173 mutação)
Plataforma	Illumina HT-12 v3 (microarranjo); sequenciamento alvo para mutações
Seguimento mediano	115,6 meses
Óbitos por qualquer causa	1.098
Óbitos atribuídos ao câncer	619
IDs duplicados / ausentes	0 / 0

Exclusões: 1 sarcoma mamário, 6 casos sem classificação de subtipo (NC).

Auditoria da codificação do desfecho — etapa crítica. Este conjunto de dados é frequentemente analisado com o evento invertido, o que produziria conclusões exatamente opostas. A tabulação cruzada (T02) confirma que `overall_survival = 1` significa **paciente viva**; o evento de óbito foi definido como `1 - overall_survival`.

Coorte de modelagem preditiva. Para os modelos de óbito em 10 anos, só entram pacientes cujo desfecho é determinado — quem morreu antes de 120 meses ou foi seguido por pelo menos 120 meses: **n = 1.560, 702 óbitos (45,0%)**. Isso evita censura

informativa.

Estágio tumoral: disponível em 1.400 pacientes (73,8%). Agrupamento: estágios 0-1 como **I** (n = 479), estágio 2 como **II** (n = 797), estágios 3-4 como **III-IV** (n = 124).

4. Métodos

4.1 Pipeline principal em R — 12 módulos

Parâmetros declarados *a priori* em um único objeto de configuração, evitando escolhas post-hoc: FDR < 0,01 e $|\Delta z| \geq 0,50$ para expressão diferencial; FDR < 0,05 para modelos de Cox; partição 70/30; 500 árvores; 10 dobras na validação cruzada; frequência mínima de 2% para mutações.

Módulo	Função
0-2	Ambiente, ingestão, integridade, auditoria do desfecho, matriz 489 × 1.897
3	Caracterização clínica por subtipo (qui-quadrado, Kruskal-Wallis, correção BH)
4	Expressão diferencial com limma — modelos lineares por gene, moderação bayesiana empírica
5	Random Forest de classificação dos 6 subtipos, erro OOB, importância
6	Cox univariado dos 489 genes em OS e DSS; teste de riscos proporcionais; Cox ajustado
7	Kaplan-Meier e Cox estratificado dentro de cada subtipo
8	Assinatura LASSO-Cox com validação em partição independente
8b	Validação repetida em 25 partições e estabilidade de seleção
9	Mutações somáticas: heterogeneidade e associação com sobrevida
10	Integração das camadas e escore de prioridade por subtipo

4.2 Análises complementares em Python

Análise	Desenho
Cox por estágio	489 modelos univariados dentro de cada estrato, correção BH separada
Interação gene × tratamento	1.467 modelos com termo de interação, ajustados por idade, grau e tamanho
Random Forest de desfecho	Óbito em 10 anos, validação cruzada 5-fold estratificada
Benchmark de 11 algoritmos	5-fold × 3 repetições, testes de Nadeau-Bengio, McNemar e DeLong
Treino final multi-algoritmo	16 modelos com busca de hiperparâmetros aninhada

4.3 Como o AUC de cada método é obtido

Este é o ponto onde a maioria dos trabalhos superestima o desempenho. O procedimento:

- Partição externa:** `StratifiedKFold(5, shuffle=True, random_state=42)`.
- Busca de hiperparâmetros DENTRO de cada dobra:** `RandomizedSearchCV` com 3 dobras internas. Escolher hiperparâmetros com o teste à vista infla a AUC.
- Seleção de variáveis dentro da dobra:** quando há seleção L1, ela é um passo do `Pipeline`, não uma etapa prévia.
- Predições fora da amostra:** `cross_val_predict` devolve, para cada paciente, a probabilidade estimada por um modelo que nunca o viu no treino.
- AUC e IC 95%:** método de **DeLong**, que estima a variância a partir dos midranks.
- Calibração:** regressão isotônica ajustada dentro da validação; avaliação por Brier e Hosmer-Lemeshow.
- Verificação da reimplementação:** cada modelo exportado é reexecutado em Python puro, percorrendo as árvores nó a nó como o JavaScript faz, e comparado ao scikit-learn. **Erro máximo: 3×10^{-6} .**

5. Resultados — caracterização clínica e molecular

5.1 Perfil clínico por subtipo

Subtipo	n (%)	Idade	Tamanho (mm)	G3 (%)	N+ (%)	ER+ (%)	HER2+ (%)	NPI	Óbitos (%)
LumA	679 (35,8)	63,2	20,5	25,9	42,3	99,6	3,1	3,08	53,6
LumB	461 (24,3)	66,2	25,0	55,6	51,4	100,0	9,1	4,05	65,7
Her2	220 (11,6)	58,8	25,0	73,7	57,3	42,3	56,8	4,08	70,5
Basal	199 (10,5)	54,5	25,0	90,5	53,8	13,6	10,1	5,02	55,8
claudin-low	198 (10,4)	58,5	20,0	67,9	47,5	38,4	7,6	4,05	44,9
Normal	140 (7,4)	57,8	23,0	34,1	40,0	85,7	9,3	4,03	54,3

As 14 variáveis clínicas testadas diferiram entre subtipos após correção BH. As mais discriminantes: status de ER (FDR = $4,0 \times 10^{-233}$), PR ($3,9 \times 10^{-106}$), HER2 ($2,8 \times 10^{-97}$) e grau histológico ($5,1 \times 10^{-80}$).

5.2 Sobrevida por subtipo e por estágio

Subtipo	n	Óbitos	Mediana de OS		Estágio	n	Óbitos	Mediana de OS
claudin-low	198	89	219,2 meses		I	479	216	227,9 meses
LumA	679	364	186,6 meses		II	797	480	140,8 meses
Normal	140	76	158,5 meses		III-IV	124	94	55,5 meses
Basal	199	111	130,9 meses					
LumB	461	303	123,0 meses					
Her2	220	155	104,0 meses					

Log-rank por subtipo: $p = 3,74 \times 10^{-10}$. Por estágio: $p = 1,21 \times 10^{-25}$ — o estágio clínico separa a coorte com força muito superior à do subtipo molecular.

O METABRIC é uma coorte majoritariamente **pré-trastuzumabe**, o que explica o Her2 aparecer com a pior sobrevida mediana. O Basal, apesar do perfil clínico mais agressivo, não ocupa a última posição — reflexo do padrão conhecido de risco precoce alto seguido de platô, enquanto os luminais mantêm risco tardio persistente. Esse cruzamento de curvas é também a razão pela qual o pressuposto de riscos proporcionais é problemático nesta coorte.

5.3 Genes que definem cada subtipo

568 associações gene-subtipo com FDR < 0,01 e $|\Delta z| \geq 0,50$ (figuras F02 , F03).

Subtipo	Marcadores principais (Δz)
Basal	$\uparrow$ CCNE1 (+1,67), CDKN2A (+1,66), CHEK1 (+1,57), E2F3 (+1,51) · $\downarrow$ TGFB3 (−1,41)
Her2	$\uparrow$ ERBB2 (+1,57), ARDC1 (+1,12), GSK3B (+1,04) · SMAD4, MYC, BCL2
LumA	$\uparrow$ GATA3 (+1,13), MAPT (+1,12), BCL2 (+0,91) · $\downarrow$ AURKA, CCNE1, E2F2
LumB	$\uparrow$ GATA3 (+1,00) · $\downarrow$ EGFR (−1,06), NOTCH1, FOXO1, SPRY2
claudin-low	$\uparrow$ FOLR2 (+1,57), KLRG1 (+1,56), CSF1R (+1,37) · $\downarrow$ ERBB3, RAB25
Normal	$\uparrow$ NR2F1, ABCB1, SPRY2 · $\downarrow$ CDK1, CHEK1, AURKA

A superexpressão de ERBB2 exatamente no subtipo Her2 funciona como **controle positivo interno**: se a pipeline não recuperasse esse achado, haveria erro de processamento em algum ponto.

5.4 Mutações somáticas

Gene	Global	LumA	LumB	Her2	Basal	claudin-low
PIK3CA	41,8%	57,4%	34,9%	41,4%	16,1%	24,2%
TP53	34,7%	11,9%	24,3%	70,0%	88,4%	52,0%
MUC16	17,2%	16,6%	16,1%	27,3%	23,1%	9,6%
GATA3	12,1%	19,6%	13,9%	7,7%	0,0%	2,0%
MAP3K1	10,3%	16,2%	8,7%	6,8%	4,5%	4,0%

O eixo TP53-mutado / PIK3CA-selvagem (Basal, Her2) contra PIK3CA-mutado / TP53-selvagem (LumA) reproduz a dicotomia estabelecida na literatura.

Associação com sobrevida: GATA3 mutado HR 0,590 (FDR $3,3 \times 10^{-5}$), CBFB 0,501, TP53 1,289. **Ressalva:** essas mutações concentram-se em subtipos específicos, de modo que os HR são fortemente confundidos pelo subtipo.

6. Resultados — genes associados à sobrevida

Cox univariado nos 489 genes, HR por +1 desvio-padrão de expressão, correção Benjamini-Hochberg. **125 genes significativos (FDR < 0,05): 61 protetores e 64 de risco.** Figura F06 .

6.1 Genes associados a MAIOR sobrevida (HR < 1)

Gene	HR (OS)	IC 95%	HR (DSS)	Comentário
IGF1	0,804	0,750–0,862	0,820	fator de crescimento; efeito protetor consistente
STAT5A	0,807	0,759–0,858	0,753	selecionado em 60% das repetições do LASSO
SPRY2	0,810	0,759–0,864	0,864	regulador negativo de RTK
CDKN2C	0,815	0,760–0,874	0,874	inibidor de CDK

FLT3	0,820	0,767–0,876	0,792	3º no ranking do Random Forest
ABCB1	0,822	0,770–0,877	0,875	transportador de efluxo
LAMA2	0,836	0,788–0,887	0,855	matriz extracelular
STAT5B	0,838	0,790–0,890	0,744	par de <i>STAT5A</i>
PDGFRA	0,844	0,796–0,895	0,945	HR 0,695 dentro do LumA ($p = 5,4 \times 10^{-11}$)
CCND2	0,846	0,796–0,899	0,898	ciclina D2
BCL2	0,849	0,801–0,900	0,723	marcador de diferenciação luminal
KIT	0,849	0,796–0,905	0,868	receptor tirosina-quinase

6.2 Genes associados a MENOR sobrevida (HR > 1)

Gene	HR (OS)	IC 95%	HR (DSS)	Comentário
GSK3B	1,225	1,159–1,295	1,326	selecionado em 72% das repetições do LASSO
AURKA	1,191	1,123–1,262	1,458	1º no Random Forest; proliferação
VEGFA	1,165	1,100–1,233	1,209	angiogênese
FANCD2	1,163	1,096–1,233	1,323	reparo de DNA
KRAS	1,153	1,086–1,224	1,199	oncogene clássico
E2F7	1,148	1,084–1,215	1,276	ciclo celular
TUBB4B	1,144	1,078–1,214	1,227	citoesqueleto
SLC19A1	1,142	1,078–1,209	1,239	transportador de folato reduzido
MMP11	1,134	1,067–1,206	1,162	remodelamento de matriz
CTCF	1,132	1,068–1,200	1,166	organização da cromatina
RPS6KB2	1,131	1,066–1,200	—	via mTOR
MAML1	1,128	1,062–1,197	—	via Notch

Os **HR** são maiores na sobrevida específica do câncer, como esperado ao remover o ruído da mortalidade competitiva: *AURKA* passa de 1,191 (OS) para 1,458 (DSS).

6.3 Após ajuste clínico

Ajustando por idade, grau, tamanho, linfonodos, subtipo e os três tratamentos, **10 dos 20 genes mais fortes mantêm significância**: *STAT5A* (0,867), *GSK3B* (1,133), *VEGFA* (1,125), *BCL2* (0,885), *CDKN2C* (0,896), *CIR1* (0,911), *STAT5B* (0,912), *IGF1* (0,910), *AURKA* (1,107), *FLT3* (0,923). A atenuação (*GSK3B* de 1,225 para 1,133) mostra que parte do efeito univariado é mediada pelo subtipo e pelo grau — mas não toda.

Alerta metodológico: entre os 20 genes mais fortes, **12 violam o pressuposto de riscos proporcionais**. Com seguimento mediano de quase 10 anos, os HR devem ser lidos como efeitos médios ao longo do seguimento, não como razões constantes.

6.4 Onde o sinal está — por subtipo e por estágio

Subtipo	n / eventos	Genes significativos		Estágio	n / eventos	Genes significativos
LumA	679 / 364	12 de 12		I	479 / 216	1 (<i>NRIP1</i> 0,729)
LumB	461 / 303	4		II	797 / 480	71
Normal	140 / 76	4		III–IV	124 / 94	1 (<i>DNAH11</i> 1,523)
claudin-low	198 / 89	0				
Her2	220 / 155	0				
Basal	199 / 111	0				

No estágio II destacam-se *ACVR1B* (1,279), *MEN1* (1,242), *MAML1* (1,236) e *AR* (1,217) como risco; *PDGFRA* (0,791), *STAT5A* (0,787), *IGF1* (0,762) e *CDKN2C* (0,777) como proteção.

A informação transcricional é útil onde existe heterogeneidade de risco a resolver. No estágio I o prognóstico já é bom para quase todas; no III–IV já é ruim para quase todas. É no estágio II — o maior e mais heterogêneo — que a expressão gênica efetivamente estratifica.

6.5 Integração: o eixo dominante é a proliferação

Cruzando marcadores de subtipo com genes prognósticos, 223 pares são simultaneamente as duas coisas. A simetria entre Basal e LumA — os mesmos genes (*AURKA*, *FANCD2*, *E2F2*, *BCL2*) com direções invertidas — indica que o eixo prognóstico dominante não

é um conjunto de genes independentes, mas um **gradiente único de proliferação**. Isso explica por que a assinatura multigênica acrescenta tão pouco a um modelo que já contém subtipo e grau: ela mede, por um caminho mais longo e instável, algo que o grau histológico já mede.

7. Resultados — aprendizado de máquina

7.1 Classificação dos subtipos moleculares

Onze algoritmos, 5-fold × 3 repetições, a partir dos 489 genes:

Modelo	Acurácia	Acurácia balanceada	F1-macro
Gradient Boosting	0,7872	0,7256	0,7430
SVM RBF	0,7760	0,7241	0,7385
Random Forest	0,7663	0,6780	0,7021
Rede neural (MLP)	0,7591	0,7166	0,7266
Regressão logística	0,7582	0,7183	0,7265
Extra Trees	0,7563	0,6595	0,6818
LDA	0,7412	0,6895	0,7044
SVM linear	0,7401	0,7107	0,7127
Naive Bayes	0,7062	0,6968	0,6808
k-NN (k = 15)	0,6375	0,5584	0,5923
Baseline	0,3579	0,1667	0,0879

O ranking é real? Só em parte. Pelo t pareado corrigido de Nadeau-Bengio, o Gradient Boosting **não é estatisticamente superior** ao SVM RBF (p = 0,254) nem ao Random Forest (p = 0,095). McNemar sobre as 1.897 predições: 130 acertos exclusivos do primeiro contra 114 do segundo, $\chi^2 = 0,922$, **p = 0,337**. A vantagem de 1,1 ponto está dentro da flutuação amostral.

São conclusões sólidas: todos superam massivamente o baseline; o k-NN é inadequado (maldição da dimensionalidade em 489 dimensões); e os modelos lineares ficam 3-5 pontos atrás dos não-lineares, indicando estrutura de interação entre genes.

Genes mais informativos: *GATA3, AURKA, EGFR, CDK1, CDC25A, MAPT, CHEK1, IGF1R, BCL2, E2F2*. O Random Forest, método multivariado e não-linear, chega aos mesmos genes que o limma identificou gene a gene.

7.2 Predição de óbito em 10 anos — os 16 modelos

Busca de hiperparâmetros aninhada, IC 95% de DeLong (figuras F01 , F02):

Conjunto	Algoritmo	Var.	AUC	IC 95%	Brier cal.	H-L p
Combinado	XGBoost	500	0,7488	0,725–0,773	0,198	0,999
Clínico	Rede neural (MLP)	11	0,7379	0,713–0,762	0,202	0,95
Clínico	XGBoost	11	0,7352	0,711–0,760	0,203	0,43
Clínico	Random Forest	11	0,7334	0,709–0,758	0,203	0,99
Clínico	Gradient Boosting	11	0,7328	0,708–0,758	0,204	0,52
Combinado	Extra Trees	500	0,7253	0,701–0,750	0,206	0,998
Clínico	Regressão logística	11	0,7190	0,694–0,744	0,208	0,65
Clínico	Extra Trees	11	0,7182	0,693–0,743	0,208	0,94
Combinado	Random Forest	500	0,7047	0,679–0,730	0,213	0,84
Combinado	Regressão logística	500	0,6914	0,665–0,717	0,217	0,26
Combinado	Rede neural (MLP)	500	0,6702	0,644–0,697	0,224	0,97
Genes	XGBoost	489	0,6632	0,636–0,690	0,223	0,99
Genes	Random Forest	489	0,6511	0,624–0,678	0,226	0,88
Genes	Extra Trees	489	0,6488	0,622–0,676	0,227	0,996
Genes	Regressão logística	489	0,6314	0,604–0,659	0,231	0,83
Genes	Rede neural (MLP)	489	0,6194	0,592–0,647	0,234	0,94

7.3 Como funciona cada algoritmo

Regressão logística. Fronteira linear: cada variável recebe um peso, os pesos são somados e a soma vira probabilidade pela função logística. É o modelo mais transparente e serve de referência: se um método complexo não a supera, a estrutura dos dados é essencialmente linear.

Random Forest. Centenas de árvores de decisão, cada uma treinada num reamostréio dos pacientes e enxergando apenas um sorteio das variáveis a cada divisão. A predição é a média. Essa dupla aleatoriedade descorrelaciona os erros: cada árvore erra de

um jeito diferente e a média cancela boa parte do ruído.

Extra Trees. Variante em que os pontos de corte são sorteados em vez de otimizados. Mais aleatoriedade aumenta o viés de cada árvore mas reduz ainda mais a variância do conjunto — por isso é o segundo melhor no conjunto combinado, com 489 variáveis de sinal fraco.

Gradient Boosting. As árvores são construídas em sequência: cada nova árvore corrige o erro residual das anteriores e entra com peso pequeno (taxa de aprendizado). Ganha precisão, mas é mais sensível a sobreajuste que a floresta.

XGBoost. Gradient boosting com freios: regularização explícita dos pesos das folhas, poda por ganho mínimo, amostragem de linhas e colunas a cada rodada e busca de cortes por histograma. É o que permite rodar boosting em 500 colunas sem decorar o treino — e por isso lidera.

Rede neural (MLP). Camada oculta com ativação não-linear e saída logística, aprendendo combinações que nenhuma variável expressa isoladamente. Lidera no conjunto clínico e é a **pior** nos genes: com 489 entradas e 1.560 casos, decora em vez de generalizar.

7.4 A expressão gênica perde para 6 variáveis clínicas

Comparação pareada genes × clínico **dentro de cada algoritmo** (t de Nadeau-Bengio, correção FDR):

Algoritmo	AUC genes	AUC clínico	Diferença	FDR
Rede neural (MLP)	0,614	0,736	−0,122	0,0003
k-NN	0,602	0,714	−0,112	0,0003
Regressão logística	0,604	0,717	−0,112	0,0003
SVM linear	0,606	0,715	−0,109	0,0005
LDA	0,607	0,715	−0,109	0,0005
SVM RBF	0,655	0,727	−0,072	0,0021
Extra Trees	0,651	0,721	−0,070	0,0005
Random Forest	0,656	0,726	−0,070	0,0016
Naive Bayes	0,630	0,693	−0,064	0,0011
Gradient Boosting	0,638	0,700	−0,061	0,0025
Regressão logística LASSO	0,654	0,714	−0,060	0,0006

Onze de onze algoritmos, todos com FDR < 0,003, na mesma direção. Não existe interpretação alternativa: a desvantagem dos 489 genes frente a 6 variáveis clínicas não é artefato de escolha de modelo, de linearidade, de regularização ou de hiperparâmetro. É propriedade dos dados.

Qualificação importante. O XGBoost sobre o conjunto combinado (0,7488) é o **único** modelo a superar o melhor puramente clínico. Isso qualifica — sem anular — a conclusão acima: a regressão logística não extraía nada dos genes além do clínico, mas um método capaz de capturar interações extrai **algum** sinal. Duas ressalvas: o IC se sobrepõe amplamente ao do MLP clínico, e o ganho custa 489 variáveis adicionais.

7.5 A assinatura multigênica que não funcionou

O LASSO-Cox selecionou 65 genes em `lambda.min` e 12 em `lambda.1se`. Em 25 partições independentes:

Modelo	C-index médio	DP	Mín	Máx
Assinatura gênica	0,5549	0,0354	0,500	0,611
Clínico	0,6553	0,0139	0,627	0,689
Combinado	0,6556	0,0142	0,634	0,691

Comparações pareadas (Wilcoxon): combinado vs. clínico → +0,0003, **p = 0,70**; assinatura vs. clínico → −0,1004, **p = 6 × 10^{−8}**.

Na amostra de derivação, o teste de razão de verossimilhança sugeria ganho espetacular ($\chi^2 = 161,5$; $p = 5,3 \times 10^{-37}$). Fora da amostra, esse ganho **desaparece por completo** — a assinatura digital do sobreajuste. Relatar apenas o valor-p intra-amostral produziria a conclusão oposta e falsa.

Estabilidade de seleção: apenas quatro genes foram escolhidos com consistência — *GSK3B* (72%), *STAT5A* (60%), *FLT3* (32%), *SPRY2* (32%); todos os demais em $\leq 12\%$.

7.6 Calibração — discriminação e calibração são coisas distintas

Antes da correção isotônica, o modelo atribuía 6,8% de risco a um grupo onde morriam 25,1%: **Hosmer-Lemeshow $\chi^2 = 779,4$; p = 5,7 × 10^{−163}**. Depois da correção ajustada dentro da validação (figura F03):

Modelo	Brier	Hosmer-Lemeshow
Clínico	0,211	p = 0,66
Genes	0,233	p = 0,25
Combinado	0,223	p = 0,20

A ordenação de risco, essa sim, sempre funcionou (figura F05):

Tercil	n	Óbitos em 10 anos	Sobrevida global mediana
Baixo	535	26,2%	217,6 meses
Médio	505	45,7%	142,4 meses
Alto	520	63,6%	85,7 meses

Log-rank $p = 1,8 \times 10^{-36}$ — 132 meses de diferença entre os extremos.

8. Resultados — onde o modelo falha

8.1 A falha do classificador é do rótulo

Matriz de confusão (figura F08), recall por classe: LumA 0,872 · LumB 0,818 · Basal 0,784 · claudin-low 0,788 · Her2 0,723 · Normal 0,350.

Qui-quadrado entre subtipo real e acerto: $\chi^2 = 195,3$; $p = 2,9 \times 10^{-40}$ — o erro não é aleatório.

O erro tem uma geometria. Todos os erros relevantes ocorrem entre pares **biologicamente adjacentes**: LumA ↔ LumB (124 erros), Normal → LumA (67), Her2 → LumB/LumA (50), claudin-low → Basal (20). O que praticamente **não** acontece é igualmente informativo: apenas 5 casos Basal foram chamados de LumA. **O modelo nunca confunde os extremos do espectro.**

Duas evidências de que a falha é do rótulo:

Variável	Teste	FDR	Associada ao erro?
Celularidade	qui-quadrado	0,0111	sim
Integrative cluster	qui-quadrado	0,0003	sim
Status de ER	qui-quadrado	0,064	limítrofe
Tamanho tumoral	Mann-Whitney	0,137	não
Grau histológico	qui-quadrado	0,620	não
Status HER2	qui-quadrado	1,000	não
Idade	Mann-Whitney	0,701	não
Carga mutacional	Mann-Whitney	0,701	não

Taxa de acerto por celularidade: **alta 82,1% → moderada 76,6% → baixa 72,7%**. Quanto menor a fração de células tumorais, maior a contaminação por tecido normal. **O modelo não está errando o cálculo — está recebendo, em parte, o transcriptoma do tecido errado.**

8.2 O modelo sabe quando não sabe

Confiança mediana nos acertos: **0,581**; nos erros: **0,442** — Mann-Whitney $p = 4,2 \times 10^{-60}$.

Faixa de confiança	n	Acerto observado
≤ 0,4	324	47,5%
0,4 - 0,5	449	68,6%
0,5 - 0,6	414	79,0%
0,6 - 0,7	350	89,7%
0,7 - 0,8	239	94,6%
0,8 - 0,9	106	98,1%
> 0,9	15	100,0%

Isso habilita uma estratégia operacional: classificar automaticamente os casos com confiança acima de 0,7 e encaminhar à revisão os 324 casos abaixo de 0,4, onde o modelo acerta pouco mais que uma moeda.

8.3 Onde a predição de sobrevida não é confiável

AUC por estrato com IC 95% bootstrap (figura F04):

Estrato	n	Eventos	AUC	IC 95%	Veredito
Normal-like	111	52	0,719	0,613–0,813	confiável
claudin-low	150	59	0,714	0,621–0,793	confiável
LumA	544	183	0,678	0,630–0,727	confiável
LumB	394	204	0,661	0,608–0,717	confiável
Her2	184	109	0,608	0,522–0,688	limítrofe
Basal	177	95	0,577	0,491–0,659	não confiável

Basal	1 / 1	33	0,377	0,491-0,655	não confiável
Estágio I	390	113	0,651	0,591-0,710	confiável
Estágio II	668	324	0,643	0,599-0,685	confiável
Estágio III-IV	109	78	0,506	0,387-0,626	não confiável

No subtipo Basal e no estágio III-IV o intervalo cruza 0,5: a predição não se distingue de um sorteio. A plataforma **bloqueia a leitura do número** nesses casos.

8.4 O erro que mais importa

O modelo erra assimetricamente: 302 falsos positivos contra 224 falsos negativos (teste binomial **p = 0,0008**). Em estratificação de risco, esse é o viés menos danoso.

Comparando os óbitos **não previstos** com os **previstos** (Mann-Whitney, todos FDR < 0,001):

Variável	Óbito não previsto	Óbito previsto
Idade ao diagnóstico	61,3 anos	69,1 anos
Tamanho tumoral	20 mm	30 mm
Índice de Nottingham	4,04	5,04
Linfonodos positivos	0	2
Tempo até o óbito	70,1 meses	46,0 meses

Os óbitos que o modelo não antecipa são de pacientes mais jovens, com tumores menores, sem linfonodos comprometidos e índice prognóstico favorável. O modelo captura bem a morte que “parece” provável pelos critérios clínicos clássicos e falha justamente nos casos que mais precisariam de um marcador molecular. Esse é o nicho não atendido, e ele coincide exatamente com o resultado de que os genes não acrescentam sinal — se acrescentassem, seria aqui.

9. Camada farmacogenômica

Para cada um dos 489 genes e cada um dos três tratamentos registrados, foi ajustado um modelo de Cox contendo o gene, o tratamento e o **termo de interação gene x tratamento** (1.467 modelos), com ajuste por idade, grau e tamanho tumoral.

Tratamento	n (tratadas / não tratadas)	Interações com FDR < 0,05
Hormonioterapia	1.170 / 727	14
Quimioterapia	396 / 1.501	0 (menor FDR: AKT151, 0,071)
Radioterapia	1.137 / 760	0

Os 14 genes com interação significativa

O HR de referência é o efeito do gene em quem **não** recebeu hormonioterapia; o HR de interação é o fator multiplicativo aplicado a quem recebeu.

Gene	HR sem terapia	HR de interação	FDR	Efeito resultante	Leitura
EIF4E	1,184	0,762	0,012	≈ 0,90	risco anulado sob terapia
TWIST1	1,205	0,779	0,013	≈ 0,94	risco anulado
DNAH2	0,802	1,294	0,013	≈ 1,04	proteção anulada
SETDB1	0,881	1,275	0,017	≈ 1,12	proteção invertida
PDGFRA	1,148	0,784	0,022	≈ 0,90	risco anulado
EPCAM	1,139	0,789	0,023	≈ 0,90	risco anulado
MYC	1,139	0,804	0,030	≈ 0,92	risco anulado
MTOR	0,891	1,243	0,030	≈ 1,11	proteção invertida
MAP3K13	0,931	1,238	0,030	≈ 1,15	proteção invertida
ACKR3	1,209	0,801	0,031	≈ 0,97	risco anulado
BAP1	0,870	1,230	0,032	≈ 1,07	proteção invertida
DTX3	0,869	1,213	0,034	≈ 1,05	proteção invertida
CASP6	1,108	0,809	0,034	≈ 0,90	risco anulado
MMP16	1,176	0,811	0,042	≈ 0,95	risco anulado

Teste de confundimento — a verificação decisiva. A hormonioterapia é prescrita conforme o status de receptor de estrogênio, então uma “interação” poderia refletir apenas a diferença entre biológicas ER+ e ER-. Reanalizando com ajuste adicional por **status de ER, subtipo molecular e quimioterapia**, os 14 permaneceram significativos (FDR entre 0,0009 e 0,013), com HR praticamente inalterados (*EIF4E* 0,762 → 0,790; *MYC* 0,804 → 0,794; *MTOR* 1,243 → 1,223).

Interpretação. Emergem dois grupos coerentes com a biologia da resistência endócrina:

- Genes de **tradução, proliferação e transição epitélio-mesenquimal** (*EIF4E, MYC, TWIST1, EPCAM, PDGFRA, MMP16, ACKR3*): alta expressão marca pior prognóstico em pacientes não tratadas, e a desvantagem desaparece sob terapia — compatível com esses tumores serem os que mais se beneficiam do bloqueio endócrino.
- Genes de **remodelamento de cromatina e sinalização mTOR** (*MTOR, SETDB1, MAP3K13, BAP1, DTX3*): alta expressão é neutra ou favorável sem terapia e passa a marcar **pior** desfecho sob hormonioterapia — perfil candidato a **resistência endócrina**, biologicamente plausível dado que a via PI3K/AKT/mTOR é o mecanismo de escape endócrino mais estabelecido no luminal.

Nomenclatura. Trata-se de farmacogenômica **somática** — expressão tumoral como modificadora de efeito do tratamento — e não da farmacogenômica clássica de polimorfismos germinativos (*CYP2D6, DPYD, UGT1A1*), para a qual o METABRIC não tem dados.

10. Plataforma de inferência

Aplicação estática de página única, com todo o cálculo no navegador — nenhum dado do usuário trafega pela rede. Os 16 modelos foram exportados como coeficientes e arrays compactos de nós de árvore, e a predição reimplementada em JavaScript puro.

Algoritmo de inferência (para reimplementar em qualquer linguagem)

```
1. Monte o vetor x na ordem exata de modelo["variaveis"]:
  - nomes iniciados por "sub_" → 1 se for o subtipo do paciente, 0 caso contrário
  - variáveis clínicas → o valor informado (NUNCA zero quando ausente)
  - demais nomes → o z-score do gene (0 = média da coorte)

2. Conforme modelo["tipo"]:
  linear      z = intercepto + Σ ((x[i] - media[i]) / escala[i]) × coef[i]; p = sigmoide(z)
  floresta    p = média, sobre as árvores, do valor da folha alcançada
  boosting_sk z = base + lr × Σ (folha de cada árvore); p = sigmoide(z)
  boosting_xgb z = logit(base) + Σ (folha de cada árvore); p = sigmoide(z)
  mlp         padronize; aplique W/b com ReLU camada a camada; saída logística

Percurso da árvore: comece no nó 0; enquanto l[i] ≠ -1, vá para l[i] se x[f[i]] < t[i],
senão para r[i]. Devolva v[i].
ATENÇÃO: a folha é identificada por l[i] = -1. No sklearn, f[i] vale -2 nas folhas.

3. Calibre: interpole linearmente o p bruto na curva modelo["calibracao"].
```

Para o **XGBoost**, `base` é a prevalência real ($\approx 0,45$), lida de `booster.save_config()`.

Decisões de projeto derivadas da análise

- **Estados de indisponibilidade explícitos.** Sem expressão carregada ou com campo clínico em branco, a tela mostra “Aguardando dados” e explica o que falta — em vez de calcular sobre um paciente médio inexistente. Campo em branco nunca vira zero.
- **O painel de confiabilidade é o elemento central**, não o número do risco. Exibe a barra de AUC com IC 95% por subtipo, com a linha do acaso marcada, e emite veredito explícito. Em Basal, a mensagem é literal: ignore o número acima.
- **Seletor de conjunto e de algoritmo**, com AUC e IC visíveis no momento da escolha, e curvas ROC sobrepostas.
- **O classificador de subtipo informa a própria confiança** e avisa abaixo de 0,6.

11. Erros cometidos e corrigidos

Registro explícito, porque cada um afetaria as conclusões:

1. Vazamento de seleção de variáveis. A primeira versão da exportação selecionava a assinatura de 106 genes usando toda a base e só depois validava. Feito:

Métrica	Com vazamento	Corrigido
AUC do modelo de genes	0,727	0,639
AUC do modelo combinado	0,768	0,692
Basal	0,710 → “confiável”	0,577 (IC 0,491-0,659) → não confiável

Se tivesse passado, a plataforma declararia confiável justamente a predição em tumores basais.

2. Laço infinito na travessia de árvores. As folhas do sklearn usam `feature = -2`, não `-1`; o teste de parada nunca disparava. Diagnosticado com `py-spy` após 13 minutos de processo travado. A condição correta é `children_left == -1`.

3. XGBoost com erro de $4,8 \times 10^{-2}$ na reimplementação. O `base_score` real é a prevalência ($\approx 0,45$), não 0,5, e os limiares precisam da precisão de float32 do booster. Após corrigir ambos, o erro caiu para $8,4 \times 10^{-8}$.

4. Sete incoerências na interface auditada. Modelo padrão contradizendo a própria nota da tela; veredito de confiabilidade de um modelo exibido para outro; predição de 40,4% exibida sem dado algum carregado; campo clínico vazio virando zero (risco caía

de 40,3% para 15,7%); subtipo indefinido caindo silenciosamente em LumA; afirmação falsa sobre “106 genes + PAM50”; e perda da CSP restritiva na migração. Todas corrigidas na versão final.

12. Limitações

1. **Sem validação externa.** Toda a validação foi interna. Confirmação em TCGA-BRCA ou coorte própria é o passo obrigatório seguinte.
2. **Cobertura gênica parcial:** 489 genes de painel curado, não o transcriptoma completo.
3. **Riscos proporcionais violados** em 12 dos 20 genes mais fortes.
4. **Coorte histórica,** majoritariamente pré-trastuzumabe, com esquemas adjuvantes heterogêneos e sem registro de duração ou adesão à hormonioterapia.
5. **Tratamento não randomizado:** interação gene x tratamento em dados observacionais é vulnerável a confundimento por indicação.
6. **Estágio ausente em 26,2%** e apenas 124 casos em III-IV.
7. **Mortalidade competitiva:** a OS inclui 480 óbitos por outras causas; o tratamento formal exigiria modelos de risco competitivo (Fine-Gray).
8. **Grupo “Normal-like”** provavelmente reflete contaminação por tecido normal.
9. **z-scores calculados sobre a coorte inteira:** aplicar a uma paciente nova exige recalibração.
10. **Sem dados de genótipo germinativo:** a camada farmacogenômica é somática, não clássica.
11. **Discriminação moderada ($\approx 0,75$),** comparável ao que o estadiamento clínico já entrega.

13. Próximos passos

Em ordem de retorno esperado:

1. **Restringir aos tumores luminais em estágio II** e rederivar a assinatura nesse contexto — é onde todo o sinal se concentra.
2. **Validar externamente** em TCGA-BRCA, com atenção à diferença de plataforma (microarranjo vs. RNA-seq).
3. **Aprofundar o eixo mTOR/*SETDB1*** como marcador de resistência endócrina, cruzando com as mutações de *PIK3CA* já disponíveis nesta coorte.
4. **Obter a matriz de expressão completa** (~24.000 genes) e repetir os módulos de expressão diferencial, Cox e assinatura.
5. **Modelos de risco competitivo** (Fine-Gray) e **Random Survival Forest**, que usa o tempo até o evento em vez de dicotomizar em 10 anos.
6. **Modelagem tempo-dependente** para os genes que violam riscos proporcionais.

14. Inventário do pacote

Pasta	Conteúdo
00_dados_entrada/	METABRIC_RNA_Mutation.csv (8,4 MB) e MD5SUM.txt
01_pipeline_R/	metabRIC_pipeline.R — 12 módulos, autossuficiente
02_analises_complementares/	Estágio, farmacogenômica, Random Forest complementar (Python)
03_benchmark_ml/	Benchmark de 11 algoritmos com testes estatísticos (Python)
04_treino_e_exportacao/	Treino dos 16 modelos e exportação para o navegador (Python)
05_figuras/	8 figuras de validação + script gerador
06_tabelas/	Genes de sobrevida (G01-G03) e métricas dos 16 modelos (G04)
07_plataforma/	Aplicação web de inferência — abra <code>index.html</code>
08_resultados_brutos/	33 tabelas do R, 13 figuras do R, todas as saídas intermediárias
09_relatorios/	Este relatório e os relatórios temáticos anteriores
EXECUTAR_TUDO.sh	Executa o pipeline completo na ordem correta
requisitos.txt	Dependências de Python e R

Figuras de validação

Figura	Conteúdo
F01_curvas_roc.png	Curvas ROC dos 6 algoritmos, nos 3 conjuntos
F02_auc_ic95.png	AUC com IC 95% de DeLong para os 16 modelos
F03_calibracao.png	Risco previsto x observado após correção isotônica
F04_confiabilidade_estratos.png	AUC por subtipo e estágio, com linha do acaso
F05_tercis_risco.png	Desfecho e sobrevida real por tercil
F06_genes_forest.png	Forest plot dos 24 genes mais fortes

F07_genes_ml_e_estagio.png	Importância no Random Forest e genes do estágio II
F08_matriz_confusao_subtipo.png	Matriz de confusão dos 6 subtipos

Bibliotecas e finalidade

R: data.table (leitura de alto desempenho), dplyr/tidyr/purrr/stringr/forcats (manipulação), **limma** (expressão diferencial com moderação bayesiana empírica), **survival** (Kaplan-Meier, log-rank, Cox, `cox.zph`), survminer (curvas com tabela de risco), **glmnet** (Cox penalizado por LASSO), **randomForest** (classificação multiclasse), matrixStats, broom, ggplot2, ggrepel, scales, RColorBrewer, viridis, pheatmap, patchwork, cowplot, gridExtra.

Python: **scikit-learn** (Random Forest, Extra Trees, Gradient Boosting, MLP, SVM, validação cruzada, calibração isotônica, métricas), **XGBoost** (boosting regularizado), **lifelines** (modelos de Cox, Kaplan-Meier, log-rank), statsmodels (Benjamini-Hochberg, McNemar), scipy (testes estatísticos), pandas/numpy, matplotlib (figuras).

15. Referências

- Curtis C, Shah SP, Chin SF, et al. The genomic and transcriptomic architecture of 2,000 breast tumours reveals novel subgroups. *Nature*. 2012;486(7403):346-352.
- Pereira B, Chin SF, Rueda OM, et al. The somatic mutation profiles of 2,433 breast cancers refine their genomic and transcriptomic landscapes. *Nat Commun*. 2016;7:11479.
- Ritchie ME, Phipson B, Wu D, et al. limma powers differential expression analyses for RNA-sequencing and microarray studies. *Nucleic Acids Res*. 2015;43(7):e47.
- Simon N, Friedman J, Hastie T, Tibshirani R. Regularization paths for Cox's proportional hazards model via coordinate descent. *J Stat Softw*. 2011;39(5):1-13.
- Breiman L. Random Forests. *Mach Learn*. 2001;45(1):5-32.
- Chen T, Guestrin C. XGBoost: a scalable tree boosting system. *KDD*. 2016:785-794.
- DeLong ER, DeLong DM, Clarke-Pearson DL. Comparing the areas under two or more correlated receiver operating characteristic curves. *Biometrics*. 1988;44(3):837-845.
- Nadeau C, Bengio Y. Inference for the generalization error. *Mach Learn*. 2003;52(3):239-281.
- Benjamini Y, Hochberg Y. Controlling the false discovery rate. *J R Stat Soc B*. 1995;57(1):289-300.
- Therneau TM, Grambsch PM. *Modeling Survival Data: Extending the Cox Model*. Springer; 2000.
- Meinshausen N, Bühlmann P. Stability selection. *J R Stat Soc B*. 2010;72(4):417-473.
- Niculescu-Mizil A, Caruana R. Predicting good probabilities with supervised learning. *ICML*. 2005:625-632.

Uso restrito a pesquisa e ensino. Não é dispositivo médico e não deve orientar decisão clínica individual.