

Uso preditivo, limites de confiabilidade e plataforma

- O modelo pode ser usado para inferência preditiva?
 - Análise de aptidão, limites de confiabilidade e documentação da plataforma
 - 1. Resposta curta
 - 2. Uma correção importante em relação ao que reportei antes
 - 3. Em que aspectos a predição é confiável
 - 4. Barreiras estruturais ao uso preditivo real
 - 5. A plataforma construída
 - 6. O que faria o modelo apto a mais do que ordenar risco

O modelo pode ser usado para inferência preditiva?

Análise de aptidão, limites de confiabilidade e documentação da plataforma

1. Resposta curta

Sim para ordenar risco; não para estimar risco individual; nunca para decisão clínica.

Três usos precisam ser separados, porque a resposta é diferente para cada um:

Uso pretendido	Apto?	Base da conclusão
Ordenar pacientes por risco (triagem para estudo, priorização de seguimento em pesquisa)	Sim	Log-rank entre tercís $p = 1,8 \times 10^{-36}$; sobrevida mediana de 217,6 contra 85,7 meses entre os extremos
Estimar a probabilidade individual de óbito em 10 anos	Com ressalvas	Calibração adequada após correção isotônica (Hosmer-Lemeshow $p = 0,66$ no modelo clínico), mas sem validação externa
Apoiar decisão clínica sobre uma paciente	Não	Sem validação externa, sem randomização, coorte histórica pré-trastuzumabe, AUC de 0,72
Substituir plataformas validadas (Oncotype, MammaPrint)	Não	Nenhuma comparação foi feita; os genes sequer superaram variáveis clínicas de rotina

2. Uma correção importante em relação ao que reportei antes

Ao preparar a exportação dos modelos, detectei **vazamento de seleção de variáveis** na primeira versão: a assinatura de 106 genes era escolhida usando toda a base e só depois submetida à validação cruzada. Isso inflou artificialmente os resultados:

Métrica	Com vazamento (incorreto)	Sem vazamento (correto)
AUC do modelo de genes	0,727	0,639
AUC do modelo combinado	0,768	0,692
Basal — AUC	0,710 (IC 0,632–0,783) → “confiável”	0,577 (IC 0,491–0,659) → não confiável

A versão corrigida faz a seleção de genes e a calibração dentro de cada partição de treino. Os números da plataforma são os da coluna da direita, e voltam a concordar com o benchmark anterior de onze algoritmos (modelo de genes $\approx 0,65$). Registro isso explicitamente porque o erro, se tivesse passado, apareceria justamente onde é mais perigoso: declarando confiável a predição em tumores basais.

3. Em que aspectos a predição é confiável

3.1 Confiável — a ordenação de risco

Os tercís de risco previsto separam a sobrevida real de forma inequívoca:

Grupo	n	Óbitos em 10 anos observados	Sobrevida global mediana
Baixo	535	26,2%	217,6 meses
Médio	505	45,7%	142,4 meses
Alto	520	63,6%	85,7 meses

Log-rank $p = 1,8 \times 10^{-36}$. Uma diferença de 132 meses entre os extremos. Para qualquer tarefa que dependa de *ordem* — selecionar pacientes de maior risco para um protocolo, definir estratos de um estudo, priorizar amostras para sequenciamento — o modelo cumpre a função.

3.2 Confiável, após correção — a calibração

Antes da correção isotônica, o modelo atribuía 6,8% de risco a um grupo onde morriam 25,1% (Hosmer-Lemeshow $p = 5,7 \times 10^{-163}$). Após a correção, ajustada dentro da validação cruzada:

Modelo	Brier	Hosmer-Lemeshow
Clínico	0,211	p = 0,66
Genes	0,233	p = 0,25
Combinado	0,223	p = 0,20

Os três passam no teste de calibração. Tabela observada contra prevista, no modelo em produção:

Risco previsto	n	Previsto	Observado
≤ 20%	161	14,8%	19,3%
20-30%	139	23,1%	26,6%
30-40%	273	36,2%	31,9%
40-50%	418	45,4%	46,2%
50-60%	148	54,2%	54,1%
60-70%	280	62,9%	62,9%
> 70%	141	76,9%	69,5%

A concordância é boa na faixa intermediária e piora nos extremos — o modelo ainda subestima risco nos casos que julga muito favoráveis e superestima nos que julga muito graves.

3.3 Não confiável — dois estratos específicos

Testando cada estrato com IC 95% por bootstrap (1.500 reamostragens):

Estrato	n	AUC	IC 95%	Veredito
Normal-like	111	0,719	0,613 - 0,813	confiável
claudin-low	150	0,714	0,621 - 0,793	confiável
LumA	544	0,678	0,630 - 0,727	confiável
LumB	394	0,661	0,608 - 0,717	confiável
Her2	184	0,608	0,522 - 0,688	limítrofe
Basal	177	0,577	0,491 - 0,659	não confiável
Estágio I	390	0,651	0,591 - 0,710	confiável
Estágio II	668	0,643	0,599 - 0,685	confiável
Estágio III-IV	109	0,506	0,387 - 0,626	não confiável

No subtipo Basal e no estágio III-IV o intervalo cruza 0,5: a predição não se distingue estatisticamente de um sorteio. **A plataforma bloqueia a leitura do número nesses casos**, em vez de exibi-lo com uma ressalva discreta.

3.4 Não confiável — o caso que mais importaria

Os óbitos que o modelo não antecipa são de pacientes **mais jovens (61,3 contra 69,1 anos), com tumores menores (20 contra 30 mm), sem linfonodos comprometidos e com índice de Nottingham favorável** (todos FDR < 0,001). É exatamente o nicho onde um marcador molecular teria valor clínico — e é onde o modelo falha. Isso não é um defeito de implementação: é a consequência direta de os genes não acrescentarem informação sobre as variáveis clínicas.

4. Barreiras estruturais ao uso preditivo real

1. **Sem validação externa.** Toda a estimativa é interna. Um modelo pode manter desempenho no próprio conjunto e desabar em outra população — é a regra, não a exceção.
2. **Coorte histórica.** Pacientes tratadas entre os anos 1980 e 2000, majoritariamente antes do trastuzumabe. O prognóstico do subtipo Her2 na base **não corresponde** ao da prática atual.
3. **Desenho observacional.** Sem randomização de tratamento; o modelo aprende também os padrões de indicação terapêutica da época.
4. **Dependência de escala.** Os z-scores são calculados sobre a própria coorte. Aplicar a uma paciente nova exige recalibrar contra uma referência — não basta padronizar isoladamente.
5. **Plataforma de medição.** Microarranjo Illumina HT-12; dados de RNA-seq não são intercambiáveis sem harmonização.
6. **AUC de 0,72 é modesto.** Comparável ao que o estadiamento clínico isolado já entrega.

5. A plataforma construída

Aplicação estática de página única, com todo o cálculo no navegador — nenhum dado do usuário trafega pela rede. Os modelos foram exportados como coeficientes (61 KB de JSON), e a predição é reimplementada em JavaScript: padronização, produto escalar, sigmoide e interpolação da curva isotônica. Verifiquei que a implementação em JS reproduz os valores do scikit-learn.

Decisões de projeto que decorrem da análise acima:

- O **modelo clínico é o padrão**, não o genômico — seria incoerente destacar o modelo que a própria análise mostrou inferior. Ao selecionar o modelo de genes ou o combinado, a interface informa que ele discrimina pior e por quê.
- O **elemento central da tela é o painel de confiabilidade**, não o número do risco. Ele mostra a barra de AUC com IC 95% para cada subtipo, com a linha do acaso marcada, e emite um veredito explícito. Em Basal, a mensagem é literal: ignore o número acima.
- O **classificador de subtipo informa a própria confiança** e avisa quando ela está abaixo de 0,6 — faixa em que acerta pouco mais que a metade das vezes.
- **Faixa de aviso permanente** no topo, com o alcance e os limites do uso.
- O **desfecho real dos casos-exemplo fica oculto** até o usuário pedir, para que a predição seja feita sem ancoragem.

Dados de entrada de exemplo

Seis pacientes reais da coorte, com os 489 valores de expressão preenchidos, escolhidos para cobrir condições clínicas distintas (exemplos_entrada.csv traz os mesmos casos no formato da planilha de treino):

Caso	Perfil	Desfecho real
Luminal A, estágio I, axila negativa	56,8 anos, grau 1, 17 mm, NPI 2,03	viva, 153,6 meses
Luminal B, estágio II, axila positiva	77,0 anos, grau 3, 40 mm, 8 linfonodos, NPI 6,08	óbito, 41,4 meses
Basal, grau 3	subtipo em que o modelo não é confiável	óbito, 8,1 meses
HER2-enriquecido, tumor grande	coorte pré-trastuzumabe	óbito, 36,3 meses
Claudin-low, evolução favorável	assinatura imune/estromal	viva, 140,5 meses
Luminal A jovem, aparência favorável	< 55 anos, 22 mm, axila negativa — e óbito	óbito, 32,6 meses

O último caso está incluído de propósito: é o modo de falha da seção 3.4. O modelo clínico atribui a ele **11,0%** de risco, e a paciente morreu em 32,6 meses. O caso demonstra, na própria interface, o limite que nenhuma métrica agregada comunica tão bem.

Publicação no Cloudflare

Deixei prontos wrangler.toml (Worker com assets), _headers (CSP restritiva, connect-src 'none' , sem enquadramento em iframe) e o passo a passo no README.md . O caminho mais curto:

```
npm install -g wrangler
wrangler login
cd plataforma_metabric
wrangler pages project create painel-metabric --production-branch main
wrangler pages deploy . --project-name painel-metabric
```

O wrangler devolve o link externo https://painel-metabric.pages.dev ao final.

Não consegui executar a publicação por você: este ambiente só alcança um conjunto restrito de domínios (PyPI, npm, GitHub), e a API do Cloudflare não está entre eles. A autenticação também exigiria sua conta. Os comandos acima rodam em qualquer máquina com Node instalado.

Dado que o material é de pesquisa e trata de prognóstico oncológico, sugiro publicar **atrás do Cloudflare Access** (Zero Trust → Access → Applications), restringindo ao domínio institucional da Fiocruz ou da UFAM. Uma URL .pages.dev aberta é indexável, e um painel de risco de câncer sem controle de acesso tende a ser lido fora do contexto de pesquisa para o qual foi feito.

6. O que faria o modelo apto a mais do que ordenar risco

1. **Validação externa em TCGA-BRCA**, com atenção à diferença de plataforma. É o passo que separa um exercício metodológico de um modelo utilizável.
2. **Restringir ao contexto onde há sinal** — luminais em estágio II — e rederivar ali.
3. **Modelos de risco competitivo** (Fine-Gray), dada a alta proporção de óbitos por outras causas.
4. **Random Survival Forest**, que usa o tempo até o evento em vez de dicotomizar em 10 anos.
5. **Coorte contemporânea**, com terapias atuais, para que o prognóstico do Her2 faça sentido.