

Farmacogenômica e prognóstico molecular no câncer de mama coorte METABRIC

- [Farmacogenômica e prognóstico molecular no câncer de mama](#)
 - [Relatório integrado da coorte METABRIC \(n = 1.897\): subtipos moleculares, estágio clínico, aprendizado de máquina e modificação de efeito por tratamento](#)
 - [1. Sumário executivo](#)
 - [2. Como ler os números deste relatório](#)
 - [3. Dados, coorte e integridade](#)
 - [4. Métodos](#)
 - [5. Resultados](#)
 - [6. Respostas diretas às perguntas da pesquisa](#)
 - [7. Limitações](#)
 - [8. Próximos passos sugeridos, em ordem de retorno esperado](#)
 - [9. Bibliotecas utilizadas e finalidade de cada uma](#)
 - [10. Inventário completo dos arquivos](#)
 - [11. Referências](#)

Farmacogenômica e prognóstico molecular no câncer de mama

Relatório integrado da coorte METABRIC (n = 1.897): subtipos moleculares, estágio clínico, aprendizado de máquina e modificação de efeito por tratamento

Coorte: METABRIC / cBioPortal `brca_metabric` · **Pacientes analisadas:** 1.897 · **Seguimento mediano:** 115,6 meses **Camadas de dados:** 489 genes de expressão (z-score), 173 genes com status mutacional, 31 variáveis clínicas, desfechos de sobrevida **Ambiente:** R 4.3.3 (pipeline principal, 12 módulos) + Python 3 / lifelines 0.30.3 / scikit-learn 1.8.0 (análises complementares) · Semente fixa 42 em todas as etapas aleatórias

1. Sumário executivo

Este relatório reúne, em um único documento, tudo o que a análise produziu sobre a coorte METABRIC — dados **reais**, sem qualquer simulação ou imputação por modelo. A investigação foi conduzida em duas etapas: um pipeline reproduzível em R (33 tabelas, 13 figuras) e um conjunto de análises complementares em Python que acrescentou três camadas ausentes na primeira rodada — **estratificação por estágio tumoral, modelos de aprendizado de máquina para desfecho de sobrevida e teste formal de interação gene x tratamento**, que é o que autoriza a leitura propriamente farmacogenômica.

Os oito achados centrais:

1. **Os subtipos moleculares diferem fortemente em prognóstico** (log-rank $p = 3,7 \times 10^{-10}$): sobrevida global mediana de 219,2 meses no claudin-low a 104,0 meses no Her2.
2. **O estágio clínico separa a coorte com muito mais força que qualquer gene isolado** (log-rank $p = 1,2 \times 10^{-25}$): mediana de 227,9 meses no estágio I, 140,8 no II e 55,5 no III-IV.
3. **568 associações gene-subtipo** significativas, com assinaturas biologicamente coerentes e um controle positivo interno perfeito (*ERBB2* superexpresso no subtipo Her2).
4. **Random Forest classifica os 6 subtipos com 76,1% de acurácia** (erro out-of-bag 23,9%) a partir apenas da expressão gênica, com *GATA3*, *EGFR*, *CDK1*, *AURKA* e *MAPT* como genes mais informativos. O erro concentra-se no grupo “Normal-like” (80,7%), o que é informativo sobre a natureza desse grupo, não um defeito do modelo.
5. **125 genes associam-se à sobrevida global e 137 à sobrevida específica por câncer**. Núcleo robusto de **pior** sobrevida: *GSK3B*, *AURKA*, *VEGFA*, *FANCD2*, *E2F2/E2F7*, *CCNE1*. Núcleo de **melhor** sobrevida: *STAT5A*, *SPRY2*, *IGF1*, *PDGFRA*, *ABCB1*, *BCL2*, *CDKN2C*, *STAT5B*, *FLT3*.
6. **O sinal prognóstico transcricional é dependente do contexto**: concentra-se nos tumores **luminais** e no **estágio II**, e praticamente desaparece em Basal, Her2, no estágio I e no estágio III-IV. Isso vale tanto para o Cox estratificado quanto para o Random Forest (AUC 0,666 nos luminais contra 0,420 no Basal).
7. **Nenhuma combinação de genes superou um modelo clínico simples fora da amostra**. A assinatura LASSO-Cox obteve C-index médio de 0,555 contra 0,655 do modelo clínico em 25 partições independentes; no Random Forest de mortalidade em 10 anos, AUC de 0,653 (genes) contra 0,730 (clínico). Este resultado negativo é relatado com destaque porque contradiz a leitura ingênua dos testes feitos apenas na amostra de derivação.
8. **Camada farmacogenômica**: 14 genes apresentam **interação significativa com hormonioterapia** (FDR < 0,05), e todos os 14 permanecem significativos após ajuste por status de ER e subtipo molecular — ou seja, não são simples reflexo de quem recebe a terapia. Para *EIF4E*, *TWIST1*, *MYC*, *PDGFRA*, *EPCAM*, *CASP6*, *ACKR3* e *MMP16*, a alta expressão é fator de risco em quem **não** recebeu hormonioterapia e deixa de sê-lo em quem recebeu; para *MTOR*, *SETDB1*, *MAP3K13*, *BAP1*, *DNAH2* e *DTX3*, o padrão se inverte. Nenhuma interação sobreviveu à correção para quimioterapia ou radioterapia.

2. Como ler os números deste relatório

Um glossário curto, para que qualquer seção possa ser lida sem consultar material externo.

Termo	O que significa aqui
z-score de expressão	Expressão do gene padronizada: 0 é a média da coorte, +1 é um desvio-padrão acima. Permite comparar genes com escalas diferentes.
HR (hazard ratio)	Risco relativo de óbito por aumento de 1 desvio-padrão na expressão do gene. HR = 1,20 → 20% mais risco; HR = 0,80 → 20% menos risco. HR = 1 significa ausência de efeito.
IC 95%	Faixa de valores compatíveis com os dados. Se o intervalo não cruza 1, o efeito é estatisticamente detectável.
FDR	Valor-p corrigido para múltiplos testes (Benjamini-Hochberg). Testar 489 genes gera falsos positivos por acaso; o FDR controla essa proporção.
Δz	Diferença de expressão média entre um subtipo e todos os demais, em desvios-padrão. É um tamanho de efeito, não apenas um p-valor.
C-index	Probabilidade de o modelo ordenar corretamente duas pacientes quanto ao risco. 0,5 = acaso; 1,0 = perfeito. Na prática oncológica, 0,65–0,70 é um modelo útil.
AUC	Análogo do C-index para classificação binária (aqui: óbito em até 10 anos). Mesma escala de leitura.
Erro out-of-bag (OOB)	Estimativa honesta de erro do Random Forest, calculada em cada árvore com os pacientes que ela não viu no treino.
OS / DSS	Sobrevida global (óbito por qualquer causa) / sobrevida específica do câncer (óbitos por outras causas são censurados, não contados como evento).
Interação gene × tratamento	Teste de se o efeito prognóstico de um gene muda conforme a paciente recebeu ou não determinado tratamento. É o desenho que sustenta uma afirmação farmacogenômica.

3. Dados, coorte e integridade

Item	Valor
Estudo	METABRIC (Curtis et al., <i>Nature</i> 2012; Pereira et al., <i>Nat Commun</i> 2016)
Arquivo	METABRIC_RNA_Mutation.csv , MD5 c619471beb87af0f9fd4e4a40058654d (verificado)
Pacientes no arquivo bruto	1.904 · Coorte analítica: 1.897
Colunas	693 (31 clínicas + 489 expressão + 173 mutação)
IDs duplicados / ausentes na matriz de expressão	0 / 0
Plataforma	Illumina HT-12 v3 (microarranjo); painel de sequenciamento alvo para mutações
Óbitos por qualquer causa	1.098
Óbitos atribuídos ao câncer de mama	619

Auditoria da codificação do desfecho. Este conjunto de dados é frequentemente analisado com o evento invertido, o que produziria conclusões exatamente opostas. A tabulação cruzada confirma que `overall_survival = 1` significa **paciente viva**; o evento de óbito foi definido como `1 - overall_survival`.

Exclusões: 1 caso de sarcoma mamário e 6 casos sem classificação de subtipo (**NC**). Nenhum caso perdido por tempo de seguimento inválido.

Estágio tumoral: disponível em 1.400 pacientes (73,8%); 497 sem registro. Estágios 0 e 1 foram agrupados como **I** (n = 479), estágio 2 como **II** (n = 797), estágios 3 e 4 como **III-IV** (n = 124), pela raridade dos extremos.

4. Métodos

4.1 Pipeline principal em R (12 módulos)

Parâmetros declarados *a priori* em um único objeto de configuração, evitando escolhas post-hoc: FDR < 0,01 e $|\Delta z| \geq 0,50$ para expressão diferencial; FDR < 0,05 para modelos de Cox; partição 70/30; 500 árvores no Random Forest; 10 dobras na validação cruzada; frequência mínima de 2% para testar mutações.

Módulo	O que faz
0–2	Ambiente, ingestão, verificação de integridade, auditoria do desfecho, montagem da matriz 489 × 1.897
3	Caracterização clínica por subtipo (qui-quadrado e Kruskal-Wallis, correção BH)
4	Expressão diferencial com limma — modelo linear por gene, contrastes um-vs-demais, moderação bayesiana empírica

5	Random Forest de classificação dos 6 subtipos, erro OOB e ranking de importância
6	Cox univariado para os 489 genes, em OS e DSS; teste de riscos proporcionais e Cox ajustado por 8 covariáveis clínicas nos 20 genes mais fortes
7	Kaplan-Meier e Cox estratificado dentro de cada subtipo
8	Assinatura multigênica LASSO-Cox com validação em partição independente
8b	Validação repetida em 25 partições e estabilidade de seleção dos genes
9	Mutações somáticas: heterogeneidade entre subtipos (Fisher com Monte Carlo) e associação com sobrevida
10	Integração das camadas e escore de prioridade por subtipo

4.2 Análises complementares em Python

Análise	Desenho
Cox por estágio	489 modelos de Cox univariados dentro de cada grupo de estágio (I, II, III-IV), correção BH separada por estágio → tabela C01
Interação gene x tratamento	1.467 modelos de Cox (489 genes x 3 tratamentos) com os termos gene, tratamento e gene x tratamento , ajustados por idade, grau e tamanho tumoral → C02 ; HR por estrato de tratamento → C03 ; reanálise dos genes significativos com ajuste adicional por status de ER, subtipo e quimioterapia → C08
Random Forest de subtipo	Replicação independente do módulo 5 em outra linguagem e outra implementação → C04
Random Forest de mortalidade em 10 anos	Classificação de óbito em até 120 meses (n = 1.642, 735 eventos), validação cruzada 5-fold estratificada, comparação entre modelo de genes, clínico e combinado → C05 , C06 ; desempenho dentro de cada subtipo e estágio → C07

Todas as bibliotecas utilizadas, com versão e finalidade específica, estão listadas na seção 9.

5. Resultados

5.1 Perfil clínico por subtipo

Subtipo	n (%)	Idade mediana	Tamanho (mm)	G3 (%)	N+ (%)	ER+ (%)	HER2+ (%)	NPI	Óbitos (%)
LumA	679 (35,8)	63,2	20,5	25,9	42,3	99,6	3,1	3,08	53,6
LumB	461 (24,3)	66,2	25,0	55,6	51,4	100,0	9,1	4,05	65,7
Her2	220 (11,6)	58,8	25,0	73,7	57,3	42,3	56,8	4,08	70,5
Basal	199 (10,5)	54,5	25,0	90,5	53,8	13,6	10,1	5,02	55,8
claudin-low	198 (10,4)	58,5	20,0	67,9	47,5	38,4	7,6	4,05	44,9
Normal	140 (7,4)	57,8	23,0	34,1	40,0	85,7	9,3	4,03	54,3

As 14 variáveis clínicas testadas diferiram entre subtipos após correção BH. As mais discriminantes: status de ER (FDR = 4,0 x 10⁻²³³), status de PR (3,9 x 10⁻¹⁰⁶), HER2 (2,8 x 10⁻⁹⁷) e grau histológico (5,1 x 10⁻⁸⁰).

5.2 Sobrevida por subtipo

Subtipo	n	Óbitos	Mediana de OS (meses)	IC 95%
claudin-low	198	89	219,2	194,1 - 238,1
LumA	679	364	186,6	169,0 - 198,1
Normal	140	76	158,5	125,8 - 203,5
Basal	199	111	130,9	83,4 - 206,6
LumB	461	303	123,0	114,9 - 143,1
Her2	220	155	104,0	88,9 - 142,4

Log-rank global: **p = 3,74 x 10⁻¹⁰**.

O METABRIC é uma coorte majoritariamente **pré-trastuzumabe**, o que explica o Her2 aparecer com a pior sobrevida mediana. O Basal, apesar do perfil clínico mais agressivo (90,5% G3, maior NPI), não ocupa a última posição em sobrevida global de longo prazo — reflexo do padrão conhecido de risco precoce alto seguido de platô, enquanto os luminais mantêm risco tardio persistente. Esse cruzamento de curvas é também a razão pela qual o pressuposto de riscos proporcionais é problemático nesta coorte (seção 5.6).

5.3 Sobrevida por estágio tumoral

Estágio	n	Óbitos	Mediana de OS (meses)
I	479	216	227,9

II	797	480	140,8
III-IV	124	94	55,5

Log-rank global: $p = 1,21 \times 10^{-25}$ — uma separação com ordem de grandeza muito superior à obtida por qualquer gene individual, e superior à do próprio subtipo molecular. Distribuição conjunta estágio × subtipo (tabela c01 e seção 5.9): o estágio I concentra LumA (211/479) e o estágio III-IV é pequeno e heterogêneo, o que limita o poder estatístico nesse estrato.

5.4 Genes que definem cada subtipo

568 associações gene-subtipo com $FDR < 0,01$ e $|\Delta z| \geq 0,50$.

Subtipo	Marcadores principais (Δz)
Basal	$\uparrow CCNE1 (+1,67)$, $CDKN2A (+1,66)$, $CHEK1 (+1,57)$, $MAP2 (+1,53)$, $E2F3 (+1,51)$, $CDC25A (+1,45)$ · $\downarrow TGFB3 (-1,41)$ — desregulação do ciclo G1/S e resposta a dano de DNA
Her2	$\uparrow ERBB2 (+1,57)$, $ARRDC1 (+1,12)$, $GSK3B (+1,04)$, $AKT1 (+0,99)$ · $\downarrow SMAD4 (-1,11)$, $MYC (-0,98)$, $BCL2 (-0,96)$
LumA	$\uparrow GATA3 (+1,13)$, $MAPT (+1,12)$, $BCL2 (+0,91)$ · $\downarrow AURKA (-0,96)$, $CCNE1 (-0,94)$, $E2F2 (-0,93)$ — baixa proliferação, diferenciação luminal preservada
LumB	$\uparrow GATA3 (+1,00)$ · $\downarrow EGFR (-1,06)$, $NOTCH1 (-0,94)$, $FOXO1 (-0,90)$, $SPRY2 (-0,90)$ — identidade luminal com perda de reguladores negativos de crescimento
claudin-low	$\uparrow FOLR2 (+1,57)$, $KLRG1 (+1,56)$, $CSF1R (+1,37)$, $TGFB2 (+1,27)$ · $\downarrow ERBB3 (-1,51)$, $RAB25 (-1,42)$ — assinatura imune/estromal com perda de identidade epitelial
Normal	$\uparrow NR2F1 (+1,05)$, $ABCB1 (+1,02)$, $SPRY2 (+0,98)$ · $\downarrow CDK1 (-1,04)$, $CHEK1 (-0,97)$, $AURKA (-0,94)$

A superexpressão de *ERBB2* exatamente no subtipo Her2 funciona como **controle positivo interno**: se a pipeline não recuperasse esse achado, haveria erro de processamento em algum ponto.

5.5 Aprendizado de máquina I — Random Forest de classificação dos subtipos

Modelo de 500 árvores treinado com os 489 genes para prever o subtipo molecular.

Implementação	Erro OOB	Acurácia
R (randomForest 4.7-1.1)	23,77%	76,2%
Python (scikit-learn 1.8.0)	23,88%	76,1%

A concordância entre duas linguagens e duas implementações independentes é uma verificação de robustez do resultado, não uma repetição redundante.

Erro por classe (matriz de confusão OOB):

Subtipo	Erro	Para onde vão os erros
LumA	11,3%	66 → LumB
LumB	18,0%	74 → LumA
Basal	20,6%	22 → Her2
claudin-low	29,8%	33 → Basal, 18 → LumA
Her2	35,5%	47 → LumB, 29 → LumA
Normal	80,7%	93 dos 140 → LumA

Genes mais importantes (concordantes entre as duas implementações): *GATA3*, *AURKA*, *EGFR*, *CDK1*, *CDC25A*, *MAPT*, *CHEK1*, *IGF1R*, *BCL2*, *E2F2*, *CCNE1*, *TGFB2*, *ERBB3*, *CCNB1*, *E2F7*, *ERBB2*.

Dois pontos interpretativos importam. Primeiro, o erro de 80,7% no grupo “Normal-like” é **informação, não falha**: quase todos os casos migram para LumA, o que é consistente com a literatura que questiona se esse grupo é uma entidade biológica ou um artefato de baixa celularidade tumoral com contaminação por tecido mamário normal. Segundo, o Random Forest é um método multivariado e não-linear que **chega aos mesmos genes** que o limma identificou gene a gene — convergência entre métodos com pressupostos diferentes.

5.6 Genes associados à sobrevida na coorte completa

125 genes com $FDR < 0,05$ para sobrevida global e 137 para sobrevida específica do câncer. Os 15 mais fortes em OS (HR por +1 desvio-padrão de expressão):

Gene	HR	IC 95%	FDR	Direção
GSK3B	1,225	1,16–1,29	$3,8 \times 10^{-10}$	pior sobrevida
STAT5A	0,807	0,76–0,86	$1,7 \times 10^{-9}$	melhor
SPRY2	0,810	0,76–0,86	$2,6 \times 10^{-8}$	melhor
IGF1	0,804	0,75–0,86	$1,0 \times 10^{-7}$	melhor

ABCB1	0,822	0,77-0,88	$2,6 \times 10^{-7}$	melhor
AURKA	1,191	1,12-1,26	$2,6 \times 10^{-7}$	pior
LAMA2	0,836	0,79-0,89	$2,6 \times 10^{-7}$	melhor
FLT3	0,820	0,77-0,88	$2,6 \times 10^{-7}$	melhor
STAT5B	0,838	0,79-0,89	$4,9 \times 10^{-7}$	melhor
CDKN2C	0,815	0,76-0,87	$5,0 \times 10^{-7}$	melhor
PDGFRA	0,844	0,80-0,89	$6,2 \times 10^{-7}$	melhor
RPS6	0,855	0,81-0,90	$1,6 \times 10^{-6}$	melhor
CCND2	0,846	0,80-0,90	$2,3 \times 10^{-6}$	melhor
BCL2	0,849	0,80-0,90	$5,0 \times 10^{-6}$	melhor
VEGFA	1,165	1,10-1,23	$5,8 \times 10^{-6}$	pior

Na sobrevida específica do câncer os efeitos são **maiores em magnitude**, como esperado ao remover o ruído da mortalidade competitiva: *AURKA* HR 1,458 (FDR $1,5 \times 10^{-20}$), *BCL2* 0,723, *MAPT* 0,735, *GSK3B* 1,326, *FANCD2* 1,323, *E2F2* 1,310, *CCNE1* 1,271.

Após ajuste por idade, grau, tamanho, linfonodos, subtipo e os três tratamentos, 10 dos 20 genes testados mantiveram significância: *STAT5A* (0,867), *GSK3B* (1,133), *VEGFA* (1,125), *BCL2* (0,885), *CDKN2C* (0,896), *CIR1* (0,911), *STAT5B* (0,912), *IGF1* (0,910), *AURKA* (1,107), *FLT3* (0,923). A atenuação dos HR (por exemplo, *GSK3B* de 1,225 para 1,133) mostra que parte do efeito univariado é mediada pelo subtipo e pelo grau — mas não toda, o que caracteriza informação prognóstica parcialmente independente.

Alerta metodológico. Entre os 20 genes mais fortes, **12 violam o pressuposto de riscos proporcionais**. Com seguimento mediano de quase 10 anos, isso é esperado: o efeito de vários genes é forte nos primeiros anos e se dilui depois. Os HR devem ser lidos como **efeitos médios ao longo do seguimento**, não como razões de risco constantes.

5.7 Onde o sinal prognóstico está — por subtipo

Testando os 12 genes mais prognósticos **dentro** de cada subtipo:

Subtipo	n / eventos	Genes significativos	Destaques
LumA	679 / 364	12 de 12	<i>PDGFRA</i> 0,695 ($p = 5,4 \times 10^{-11}$), <i>SPRY2</i> 0,692, <i>IGF1</i> 0,727, <i>ABCB1</i> 0,741, <i>CDKN2C</i> 0,746, <i>STAT5A</i> 0,757, <i>GSK3B</i> 1,273
LumB	461 / 303	4	<i>GSK3B</i> 1,304, <i>IGF1</i> 0,807, <i>STAT5A</i> 0,829, <i>FLT3</i> 0,798
Normal	140 / 76	4	<i>AURKA</i> 1,835 ($p = 5,8 \times 10^{-4}$), <i>GSK3B</i> 1,388, <i>STAT5B</i> 0,674, <i>FLT3</i> 0,648
claudin-low	198 / 89	0	efeitos fracos, nenhum sobrevive ao FDR
Her2	220 / 155	0	—
Basal	199 / 111	0	—

Nos subtipos Her2 e Basal, o próprio subtipo já determina a maior parte do risco e a expressão desses genes acrescenta pouco. A consequência prática é direta: **um painel prognóstico derivado da coorte inteira será, na prática, um painel para doença luminal**.

5.8 Onde o sinal prognóstico está — por estágio

Cox univariado dos 489 genes dentro de cada estrato de estágio (análise complementar C01):

Estágio	n / eventos	Genes com FDR < 0,05	Principais
I	479 / 216	1	<i>NRIP1</i> 0,729 (FDR 0,0097). Abaixo do limiar, mas coerentes: <i>STAT5A</i> 0,786, <i>CDKN2C</i> 0,775, <i>MAPT</i> 0,808 (proteção); <i>FN1</i> 1,260, <i>MMP11</i> 1,276, <i>E2F7</i> 1,269 (risco)
II	797 / 480	71	Risco: <i>ACVR1B</i> 1,279, <i>MEN1</i> 1,242, <i>MAML1</i> 1,236, <i>AR</i> 1,217, <i>VEGFA</i> 1,181, <i>SMARCC2</i> 1,212. Proteção: <i>PDGFRA</i> 0,791, <i>STAT5A</i> 0,787, <i>IGF1</i> 0,762, <i>CCND2</i> 0,790, <i>CDKN2C</i> 0,777, <i>PTPN22</i> 0,780, <i>JAK2</i> 0,800, <i>LAMA2</i> 0,804
III-IV	124 / 94	1	<i>DNAH11</i> 1,523 (FDR 0,039); nenhum outro sobrevive à correção

O padrão espelha o encontrado por subtipo: **a informação transcricional é útil onde existe heterogeneidade de risco a resolver**. No estágio I o prognóstico já é bom para quase todas as pacientes; no III-IV já é ruim para quase todas (e $n = 124$ limita o poder); é no **estágio II** — o maior grupo e o mais heterogêneo — que a expressão gênica efetivamente estratifica.

Note também a convergência entre os dois eixos: *STAT5A*, *PDGFRA*, *IGF1* e *CDKN2C* aparecem como protetores tanto no LumA

quanto no estágio II, e *VEGFA* como fator de risco em ambos.

5.9 Aprendizado de máquina II — Random Forest para o desfecho de sobrevida

Classificação de **óbito em até 10 anos** (n = 1.642, 735 eventos), validação cruzada 5-fold estratificada.

Modelo	Variáveis	AUC
Expressão gênica	489 genes	0,653
Clínico	idade, grau, tamanho, linfonodos, NPI, subtipo	0,730
Combinado	genes + clínico	0,715

Genes mais importantes no modelo de desfecho (índice de Gini): *AURKA*, *STAT5A*, *FLT3*, *DIRAS3*, *STAT5B*, *GSK3B*, *MAPT*, *NCOA3*, *BCL2*, *MAP2K4*, *RUNX1*, *IGF1R*, *E2F2*, *ABCB1*, *VEGFA*, *IGF1*.

Esse ranking é notável por dois motivos. Primeiro, ele é **quase disjunto** do ranking de importância para classificar subtipos (*GATA3*, *EGFR*, *CDK1*, *CDC25A*): os genes que melhor definem *o que* o tumor é não são os mesmos que melhor predizem *o que vai acontecer* com a paciente — com a exceção instrutiva de *AURKA*, que lidera as duas listas. Segundo, ele **reproduz de forma independente** o núcleo identificado pelo Cox e pela seleção estável do LASSO (*AURKA*, *STAT5A*, *GSK3B*, *FLT3*, *BCL2*), apesar de o Random Forest não assumir linearidade nem proporcionalidade de riscos. Três famílias metodológicas distintas convergem para o mesmo conjunto de genes.

Desempenho por estrato — a mesma dependência de contexto:

Estrato	n / eventos	AUC (só genes)
Luminais (LumA + LumB)	986 / 410	0,666
LumA	574 / 196	0,648
claudin-low	158 / 61	0,596
LumB	412 / 214	0,580
Her2	196 / 113	0,558
Basal	180 / 97	0,420 (abaixo do acaso)
Estágio I	408 / 116	0,612
Estágio II	691 / 338	0,601
Estágio III-IV	113 / 79	0,549

O AUC de 0,420 no Basal não indica um sinal invertido explorável — indica **ausência de sinal** com flutuação amostral em um estrato pequeno. A leitura correta é que, dentro do subtipo Basal, a expressão desses 489 genes não carrega informação prognóstica utilizável.

5.10 Assinatura multigênica: o que ela ensina ao não funcionar

O LASSO-Cox selecionou 65 genes em `lambda.min` e 12 em `lambda.1se` (*FLT3*, *CDKN2C*, *SMAD6*, *STAT5A*, *GSK3B*, *MMP25*, *VEGFA*, *ABCB1*, *SPRY2*, *IGF1*, *CTCF*, *PDGFRA*).

Desempenho em 25 partições independentes:

Modelo	C-index médio	DP	Mín	Máx
Assinatura gênica	0,5549	0,0354	0,500	0,611
Clínico	0,6553	0,0139	0,627	0,689
Combinado	0,6556	0,0142	0,634	0,691

Comparações pareadas (Wilcoxon): combinado vs. clínico → **+0,0003, p = 0,70** (nenhum ganho); assinatura vs. clínico → **−0,1004, p = 6 × 10^{−8}** (a assinatura é claramente inferior).

Na amostra de derivação, o teste de razão de verossimilhança sugeria que a assinatura acrescentava informação de forma espetacular ($\chi^2 = 161,5$; $p = 5,3 \times 10^{-37}$). Fora da amostra, esse ganho **desaparece por completo**. Essa discrepância é a assinatura digital do sobreajuste: com 489 candidatos e cerca de 1.100 eventos, o LASSO captura estrutura específica do conjunto de treino. Some-se a isso que o subtipo molecular já está no modelo clínico e ele próprio é um resumo da expressão gênica — a assinatura, em boa parte, apenas reexpressa informação já contida no subtipo e no grau. Relatar apenas o valor-p intra-amostral produziria a conclusão oposta e falsa.

Estabilidade de seleção nas 25 repetições: apenas quatro genes foram escolhidos com alguma consistência — **GSK3B (72%), STAT5A (60%), FLT3 (32%) e SPRY2 (32%)**; todos os demais ficaram em $\leq 12\%$. A lista de 65 genes é em grande parte instável, mas o núcleo *GSK3B* / *STAT5A* é reprodutível e coincide com o Cox univariado, o Cox ajustado e o Random Forest de desfecho.

5.11 Mutações somáticas

Dos 173 genes com dado mutacional, 71 alcançaram frequência $\geq 2\%$.

Gene	Global	LumA	LumB	Her2	Basal	claudin-low	Normal
------	--------	------	------	------	-------	-------------	--------

PIK3CA	41,8%	57,4%	34,9%	41,4%	16,1%	24,2%	50,0%
TP53	34,7%	11,9%	24,3%	70,0%	88,4%	52,0%	22,9%
MUC16	17,2%	16,6%	16,1%	27,3%	23,1%	9,6%	10,0%
GATA3	12,1%	19,6%	13,9%	7,7%	0,0%	2,0%	8,6%
MAP3K1	10,3%	16,2%	8,7%	6,8%	4,5%	4,0%	10,0%
CDH1	9,1%	12,7%	9,8%	5,0%	2,0%	4,0%	12,9%

O eixo *TP53*-mutado / *PIK3CA*-selvagem (Basal, Her2) contra *PIK3CA*-mutado / *TP53*-selvagem (LumA) reproduz com precisão a dicotomia estabelecida na literatura — outra validação implícita da pipeline.

Associação com sobrevida global: *GATA3* mutado HR 0,590 (FDR $3,3 \times 10^{-5}$), *CBFB* mutado 0,501 ($1,3 \times 10^{-3}$), *TP53* mutado 1,289 ($1,3 \times 10^{-3}$). **Ressalva:** essas mutações concentram-se em subtipos específicos, de modo que os HR são fortemente confundidos pelo subtipo e não devem ser lidos como efeito causal independente.

5.12 Camada farmacogenômica — modificação do efeito prognóstico pelo tratamento

Esta é a análise que sustenta a leitura farmacogenômica do trabalho. Para cada um dos 489 genes e cada um dos três tratamentos registrados, foi ajustado um modelo de Cox contendo o gene, o tratamento e o **termo de interação gene × tratamento**, com ajuste por idade, grau e tamanho tumoral (1.467 modelos, correção BH separada por tratamento).

Tratamento	n (tratadas / não tratadas)	Interações com FDR < 0,05
Hormonioterapia	1.170 / 727	14
Quimioterapia	396 / 1.501	0 (menor FDR: <i>AKT1S1</i> , 0,071)
Radioterapia	1.137 / 760	0 (menor FDR: <i>PRPS2</i> , 0,272)

Os 14 genes com interação significativa com hormonioterapia. O HR de referência é o efeito do gene em quem **não** recebeu hormonioterapia; o HR de interação é o fator multiplicativo aplicado a quem recebeu; a última coluna é o efeito resultante nas tratadas.

Gene	HR sem hormonioterapia	HR de interação	FDR	HR resultante nas tratadas	Leitura
EIF4E	1,184	0,762	0,012	≈ 0,90	risco anulado sob terapia
TWIST1	1,205	0,779	0,013	≈ 0,94	risco anulado
DNAH2	0,802	1,294	0,013	≈ 1,04	proteção anulada
SETDB1	0,881	1,275	0,017	≈ 1,12	proteção invertida
PDGFRA	1,148	0,784	0,022	≈ 0,90	risco anulado
EPCAM	1,139	0,789	0,023	≈ 0,90	risco anulado
MYC	1,139	0,804	0,030	≈ 0,92	risco anulado
MTOR	0,891	1,243	0,030	≈ 1,11	proteção invertida
MAP3K13	0,931	1,238	0,030	≈ 1,15	proteção invertida
ACKR3	1,209	0,801	0,031	≈ 0,97	risco anulado
BAP1	0,870	1,230	0,032	≈ 1,07	proteção invertida
DTX3	0,869	1,213	0,034	≈ 1,05	proteção invertida
CASP6	1,108	0,809	0,034	≈ 0,90	risco anulado
MMP16	1,176	0,811	0,042	≈ 0,95	risco anulado

Teste de confundimento — a verificação decisiva. A hormonioterapia não é atribuída ao acaso: ela é prescrita conforme o status de receptor de estrogênio. Uma “interação” poderia, portanto, ser apenas o reflexo de que tumores ER+ e ER– têm biologias diferentes. Para separar as duas explicações, os 14 genes foram reanalisados com ajuste adicional por **status de ER, subtipo molecular e quimioterapia** (tabela C08):

Os 14 permaneceram significativos (FDR entre 0,0009 e 0,013), com HR de interação praticamente inalterados — por exemplo, *EIF4E* de 0,762 para 0,790; *MYC* de 0,804 para 0,794; *MTOR* de 1,243 para 1,223. Ou seja, a modificação de efeito **não é explicada** por quem recebe a terapia nem pelo subtipo do tumor.

Interpretação. Emergem dois grupos coerentes com a biologia da resistência endócrina:

- Genes ligados à **tradução, proliferação e transição epitélio-mesenquimal** (*EIF4E*, *MYC*, *TWIST1*, *EPCAM*, *PDGFRA*, *MMP16*, *ACKR3*): sua alta expressão marca pior prognóstico em pacientes não tratadas com hormonioterapia, e essa desvantagem deixa de existir sob a terapia — padrão compatível com esses tumores serem justamente os que mais se beneficiam do bloqueio endócrino.
- Genes de **remodelamento de cromatina e sinalização mTOR** (*MTOR*, *SETDB1*, *MAP3K13*, *BAP1*, *DTX3*): sua alta expressão é neutra ou favorável sem terapia e passa a marcar **pior** desfecho sob hormonioterapia — um perfil candidato a **resistência endócrina**, e biologicamente plausível dado que a via PI3K/AKT/mTOR é o mecanismo de escape endócrino mais bem estabelecido no câncer de mama luminal (e alvo clínico de inibidores de mTOR).

Ausência de sinal para quimioterapia e radioterapia. Nenhuma interação sobreviveu à correção. Para quimioterapia isso é

em boa parte uma questão de poder: apenas 396 pacientes tratadas, com 212 eventos. Vale registrar como sinal exploratório, sem valor confirmatório, que os menores FDR apontaram *AKT1S1*, *SLC19A1*, *SF3B1* e *ERBB2* — nomes plausíveis (*SLC19A1* é o transportador de folato reduzido, via de entrada do metotrexato, componente do esquema CMF usado nessa coorte histórica).

5.13 Integração das camadas — genes prioritários por subtipo

Cruzando marcadores de subtipo com genes prognósticos, 223 pares gene-subtipo são simultaneamente as duas coisas. Escore de prioridade = $|\Delta z| \times |\log \text{HR}| \times -\log_{10}(\text{FDR})$.

Subtipo	Genes prioritários	Leitura
Basal	<i>AURKA</i> (↑, HR 1,19), <i>FANCD2</i> (↑, 1,16), <i>VEGFA</i> (↑, 1,16), <i>IGF1</i> (↓, 0,80), <i>LAMA2</i> (↓), <i>BCL2</i> (↓)	Coerentes com pior prognóstico: superexpressa genes de risco e perde genes protetores
Her2	<i>GSK3B</i> (↑, 1,22), <i>AURKA</i> (↑), <i>SPRY2</i> (↓), <i>BCL2</i> (↓), <i>STAT5B</i> (↓), <i>KIT</i> (↓)	Pior prognóstico, dominado pela superexpressão de <i>GSK3B</i>
LumB	<i>SPRY2</i> (↓), <i>ABCB1</i> (↓), <i>STAT5A</i> (↓), <i>PDGFRA</i> (↓), <i>CCND2</i> (↓)	Pior prognóstico por perda de genes protetores , não por ganho de genes de risco
LumA	<i>AURKA</i> (↓), <i>BCL2</i> (↑), <i>FANCD2</i> (↓), <i>E2F7</i> (↓), <i>E2F2</i> (↓)	Perfil de melhor prognóstico — o espelho exato do Basal
claudin-low	<i>STAT5A</i> (↑), <i>ABCB1</i> (↑), <i>IGF1</i> (↑), <i>CDKN2C</i> (↑), <i>CCND2</i> (↑)	Melhor prognóstico, consistente com a maior sobrevida mediana
Normal	<i>SPRY2</i> (↑), <i>ABCB1</i> (↑), <i>LAMA2</i> (↑), <i>AURKA</i> (↓), <i>KIT</i> (↑)	Melhor prognóstico

A simetria entre Basal e LumA — os mesmos genes (*AURKA*, *FANCD2*, *E2F2*, *BCL2*) com direções invertidas — indica que o eixo prognóstico dominante na coorte não é um conjunto de genes independentes, mas um **gradiente único de proliferação**. Isso também explica por que a assinatura LASSO acrescenta tão pouco a um modelo que já contém subtipo e grau: ela está medindo, por um caminho mais longo e mais instável, algo que o grau histológico já mede.

6. Respostas diretas às perguntas da pesquisa

Quais genes definem cada subtipo molecular? *ERBB2* (Her2); *CCNE1*, *CDKN2A*, *CHEK1*, *E2F3*, *CDC25A* (Basal); *GATA3*, *MAPT*, *BCL2* (LumA); perda de *EGFR*, *NOTCH1*, *FOXO1*, *SPRY2* (LumB); *FOLR2*, *KLRG1*, *CSF1R*, *TGFB2* com perda de *ERBB3* e *RAB25* (claudin-low). No plano mutacional: *TP53* (Basal, Her2) contra *PIK3CA*, *GATA3*, *MAP3K1*, *CBFB* (LumA).

Quais genes se associam a MENOR sobrevida? *GSK3B* (HR 1,23 bruto; 1,13 ajustado; selecionado em 72% das repetições do LASSO), *AURKA* (1,19 em OS; 1,46 em mortalidade específica; primeiro no ranking do Random Forest de desfecho), *VEGFA* (1,17; 1,13 ajustado), *FANCD2*, *E2F2*, *E2F7*, *CCNE1*. Por estágio, no estágio II acrescentam-se *ACVR1B* (1,28), *MEN1* (1,24), *MAML1* (1,24) e *AR* (1,22).

Quais genes se associam a MAIOR sobrevida? *STAT5A* (HR 0,81; segundo no ranking do Random Forest; selecionado em 60% das repetições), *SPRY2* (0,81), *IGF1* (0,80), *ABCB1* (0,82), *FLT3* (0,82), *CDKN2C* (0,82), *STAT5B* (0,84), *PDGFRA* (0,84), *BCL2* (0,85), *CCND2* (0,85), *LAMA2* (0,84). No estágio I, *NR1P1* (0,73) é o único a atingir significância.

Em que contexto esses genes funcionam como marcadores? Nos tumores **luminais** (12 de 12 genes significativos no LumA; AUC 0,666 no Random Forest) e no **estágio II** (71 genes significativos). Nos subtipos Her2 e Basal, e nos estágios I e III-IV, praticamente nenhum gene sobrevive à correção para múltiplos testes. O contexto molecular e clínico não é um detalhe do resultado — é parte do resultado.

Existe sinal farmacogenômico? Sim, e apenas para hormonioterapia: 14 genes modificam significativamente o efeito prognóstico conforme a paciente tenha recebido ou não o bloqueio endócrino, e todos resistem ao ajuste por status de ER e subtipo. O grupo *MTOR* / *SETDB1* / *MAP3K13* / *BAP1* é o candidato mais interessante a marcador de resistência endócrina. Para quimioterapia e radioterapia, nenhuma interação sobreviveu à correção — para quimioterapia, sobretudo por limitação de poder (396 tratadas).

Com que grau de confiança? **Alto** para a existência das associações: $n = 1.897$, FDR rigoroso, efeitos replicados entre OS e DSS, entre R e Python, e entre três famílias metodológicas (modelos lineares, Cox, Random Forest). **Baixo** para utilidade preditiva incremental: nenhuma combinação de genes superou, fora da amostra, um modelo clínico simples — nem por LASSO-Cox (0,555 contra 0,655) nem por Random Forest (0,653 contra 0,730). **Intermediário e exploratório** para a camada farmacogenômica: os achados são estatisticamente sólidos e resistentes a confundimento medido, mas derivam de uma coorte observacional histórica, sem randomização de tratamento e sem validação externa.

7. Limitações

- Cobertura gênica parcial.** 489 genes de um painel curado, não o transcriptoma completo (~24.000 genes). Genes prognósticos fora do painel não podem ser detectados, e análises de enriquecimento de vias ficariam enviesadas pela composição do painel.
- Riscos proporcionais violados** em 12 dos 20 genes mais fortes; os HR são efeitos médios ao longo de quase 10 anos de seguimento.
- Ausência de validação externa.** Toda a validação foi interna (25 partições, validação cruzada 5-fold). Confirmação em TCGA-BRCA ou coorte própria é o passo obrigatório seguinte.

4. **Coorte histórica.** METABRIC é majoritariamente pré-trastuzumabe, com esquemas adjuvantes heterogêneos e sem registro de duração ou adesão à hormonioterapia (apenas sim/não). Os achados farmacogenômicos refletem a prática de uma era.
5. **Tratamento não randomizado.** Interação gene x tratamento em dados observacionais é vulnerável a confundimento por indicação. O ajuste por ER e subtipo mitiga a explicação mais óbvia, mas não substitui um ensaio.
6. **Estágio ausente em 26,2% das pacientes** e apenas 124 casos em III-IV, o que limita fortemente o poder nesse estrato.
7. **Mortalidade competitiva.** A OS inclui 480 óbitos por outras causas em coorte de mediana etária elevada; a análise de DSS mitiga, mas o tratamento formal exigiria modelos de risco competitivo (Fine-Gray).
8. **Grupo “Normal-like”** provavelmente reflete contaminação por tecido normal (80,7% de erro de classificação); resultados nesse estrato pedem cautela.
9. **z-scores calculados sobre a coorte inteira** implicam que o valor de cada amostra depende da composição do estudo, limitando a aplicação direta do escore a uma paciente individual sem recalibração.
10. **Ausência de dados de genótipo germinativo.** Farmacogenômica clássica estuda polimorfismos em genes de metabolização (*CYP2D6* para tamoxifeno, *DPYD*, *UGT1A1*). O que este trabalho analisa é **expressão tumoral como modificadora de efeito do tratamento** — uma farmacogenômica somática, que deve ser descrita como tal.

8. Próximos passos sugeridos, em ordem de retorno esperado

1. **Restringir o escopo aos tumores luminais em estágio II** e rederivar a assinatura nesse contexto. É onde todo o sinal se concentra e a hipótese mais promissora para superar o modelo clínico.
2. **Validar externamente** os 14 genes de interação com hormonioterapia em TCGA-BRCA, com atenção à diferença de plataforma (microarranjo vs. RNA-seq).
3. **Aprofundar o eixo mTOR/*SETDB1*** como marcador de resistência endócrina, incluindo o cruzamento com mutações de *PIK3CA* já disponíveis nesta mesma coorte.
4. **Obter a matriz de expressão completa** (~24.000 genes) do cBioPortal e repetir os módulos de expressão diferencial, Cox e assinatura.
5. **Modelagem tempo-dependente** para os 12 genes que violam riscos proporcionais, ou restrição da janela de análise (OS em 5 anos).
6. **Modelos de risco competitivo** (Fine-Gray) dada a alta proporção de óbitos por outras causas.
7. **Random Survival Forest e gradient boosting de sobrevida**, que usam o tempo até o evento diretamente em vez de dicotomizar em 10 anos.

9. Bibliotecas utilizadas e finalidade de cada uma

R (pipeline principal)

Pacote	Versão	Finalidade nesta análise
data.table	1.14.10	Leitura de alto desempenho do CSV de 8,1 MB e escrita das 33 tabelas
dplyr	1.1.4	Filtros, agrupamentos e sumarizações
tidyr	1.3.1	Conversões wide↔long para heatmaps e boxplots
purrr	1.0.2	Iteração funcional sobre os 489 genes nos modelos de Cox
stringr	1.5.1	Normalização de nomes de genes e rótulos
forcats	1.0.0	Ordenação de fatores em gráficos
limma	3.58.1	Núcleo da expressão diferencial: modelos lineares por gene com moderação bayesiana empírica da variância
survival	3.5-8	Objetos <code>Surv</code> , Kaplan-Meier, log-rank, modelos de Cox, teste <code>cox.zph</code> , concordância
survminer	0.4.9	Curvas de sobrevida com tabela de números sob risco
glmnet	4.1-8	Cox penalizado por LASSO com validação cruzada
randomForest	4.7-1.1	Classificação multiclasse dos subtipos e importância dos genes
matrixStats	1.2.0	Estatísticas por linha da matriz de expressão no controle de qualidade
broom	1.0.5	Padronização de saídas de modelos
ggplot2	3.4.4	Motor gráfico das 13 figuras
ggrepel	0.9.5	Rótulos sem sobreposição nos volcano plots
scales	1.3.0	Formatação de eixos
RColorBrewer	1.1-3	Paleta divergente dos heatmaps
viridis	0.6.5	Escalas contínuas perceptualmente uniformes
pheatmap	1.0.12	Heatmap com clusterização hierárquica
patchwork	1.2.0	Composição de painéis
cowplot	1.1.3	Tema gráfico consistente

gridExtra	2.3	Manipulação de objetos grid na exportação
-----------	-----	---

Python (análises complementares)

Pacote	Versão	Finalidade nesta análise
lifelines	0.30.3	Modelos de Cox por estágio, termos de interação gene x tratamento, Kaplan-Meier e log-rank por estágio
scikit-learn	1.8.0	Random Forest (subtipo e mortalidade em 10 anos), validação cruzada estratificada, AUC
statsmodels	—	Correção de Benjamini-Hochberg para múltiplos testes
pandas / numpy	3.0.2 / —	Manipulação da matriz de dados e operações numéricas

10. Inventário completo dos arquivos

10.1 Pipeline em R — 33 tabelas ([saidas/tabelas/](#))

Arquivo	Conteúdo
T01-T04	Integridade dos dados, auditoria da codificação do evento, fluxograma de exclusões, QC dos 489 genes
T05-T06	Caracterização clínica por subtipo e testes de associação
T07	2.934 linhas — expressão diferencial completa (489 genes x 6 subtipos)
T08-T09	Resumo da expressão diferencial e top 15 genes por subtipo
T10-T11	Matriz de confusão e ranking de importância do Random Forest
T12-T13	Cox univariado dos 489 genes para OS e para DSS
T14-T15	Teste de riscos proporcionais e Cox ajustado por 8 covariáveis
T16-T17	Medianas de sobrevida por subtipo e log-rank dos 4 genes principais
T18	Cox estratificado: 12 genes x 6 subtipos
T19, T19b, T20-T22	Assinatura LASSO (65 e 12 genes), C-index dos 5 modelos, razão de verossimilhança, tercís de risco
T23-T24	Frequência mutacional por subtipo e Cox das mutações
T25-T26	223 pares gene-subtipo integrados e genes prioritários por subtipo
T27-T28	Resumo da execução e versões das 22 bibliotecas
T29-T32	Validação repetida em 25 partições, resumo, comparações pareadas, estabilidade de seleção

10.2 Pipeline em R — 13 figuras ([saidas/figuras/](#))

F01 distribuição dos subtipos · F02 volcano por subtipo · F03 heatmap dos genes discriminantes · F04 importância no Random Forest · F05 forest plot do Cox univariado · F06 Kaplan-Meier por subtipo · F07 Kaplan-Meier dos 4 genes principais · F08 heatmap do Cox estratificado · F09 grupos de risco na validação · F10 coeficientes do LASSO · F11 mutações por subtipo · F12 integração subtipo x prognóstico · F13 estabilidade e validação repetida

10.3 Análises complementares ([saidas_complementares/](#))

Arquivo	Conteúdo
C01_cox_por_estagio_todos_genes.csv	489 genes x 3 estágios: HR, IC 95%, p, FDR
C02_interacao_gene_tratamento.csv	1.467 modelos de interação gene x tratamento
C03_cox_por_estrato_tratamento.csv	HR dos genes-núcleo dentro de cada estrato de tratamento
C04_rf_subtipo_importancia.csv	Importância dos 489 genes na classificação dos subtipos (Python)
C05_rf_mortalidade10a_importancia.csv	Importância dos 489 genes na predição de óbito em 10 anos
C06_rf_auc_mortalidade10a.csv	AUC dos modelos de genes, clínico e combinado
C07_rf_auc_por_estrato.csv	AUC por subtipo e por estágio
C08_interacao_hormonio_ajustada_ER_subtipo.csv	Reanálise dos 14 genes com ajuste por ER, subtipo e quimioterapia

10.4 Código e reprodutibilidade

- `metabric_pipeline.R` — script único, autossuficiente: detecta o próprio diretório, instala dependências ausentes, baixa os dados, verifica o MD5 e executa os 12 módulos. Execução: `Rscript metabric_pipeline.R` (~6,6 min).
- `analise_complementar.py`, `parte_b_farmaco.py`, `parte_c_rf.py` — análises de estágio, farmacogenômica e aprendizado de máquina.
- `saidas/objetos_analise.rds` — todos os objetos da análise, para reanálise sem reexecutar.
- `saidas/logs/execucao.log` e `sessionInfo.txt` — ambiente exato para reprodução.

11. Referências

- Curtis C, Shah SP, Chin SF, et al. The genomic and transcriptomic architecture of 2,000 breast tumours reveals novel subgroups. *Nature*. 2012;486(7403):346-352.
- Pereira B, Chin SF, Rueda OM, et al. The somatic mutation profiles of 2,433 breast cancers refine their genomic and transcriptomic landscapes. *Nat Commun*. 2016;7:11479.
- Ritchie ME, Phipson B, Wu D, et al. limma powers differential expression analyses for RNA-sequencing and microarray studies. *Nucleic Acids Res*. 2015;43(7):e47.
- Simon N, Friedman J, Hastie T, Tibshirani R. Regularization paths for Cox's proportional hazards model via coordinate descent. *J Stat Softw*. 2011;39(5):1-13.
- Breiman L. Random Forests. *Mach Learn*. 2001;45(1):5-32.
- Benjamini Y, Hochberg Y. Controlling the false discovery rate. *J R Stat Soc B*. 1995;57(1):289-300.
- Therneau TM, Grambsch PM. *Modeling Survival Data: Extending the Cox Model*. Springer; 2000.
- Meinshausen N, Bühlmann P. Stability selection. *J R Stat Soc B*. 2010;72(4):417-473.