

Comparação de algoritmos de aprendizado de máquina e anatomia dos erros

- [Comparação de algoritmos de aprendizado de máquina e anatomia dos erros](#)
 - [Extensão do relatório METABRIC — 11 algoritmos, 36 combinações modelo x conjunto de variáveis, com validação estatística formal](#)
 - [1. Por que comparar vários algoritmos, e por que testar a comparação](#)
 - [2. Tarefa 1 — Classificação dos seis subtipos moleculares](#)
 - [3. Tarefa 2 — Predição de óbito em até 10 anos](#)
 - [4. Síntese — o que ficou demonstrado](#)
 - [5. Arquivos gerados](#)

Comparação de algoritmos de aprendizado de máquina e anatomia dos erros

Extensão do relatório METABRIC — 11 algoritmos, 36 combinações modelo x conjunto de variáveis, com validação estatística formal

Coorte: 1.897 pacientes (classificação de subtipo) e 1.560 pacientes com desfecho de 10 anos determinado (predição de sobrevida) **Protocolo:** validação cruzada estratificada 5-fold repetida 3 vezes (15 partições por modelo), sementes fixas **Testes empregados:** t pareado corrigido de Nadeau-Bengio, McNemar, DeLong, qui-quadrado, Mann-Whitney, binomial, Hosmer-Lemeshow, log-rank

1. Por que comparar vários algoritmos, e por que testar a comparação

Um único modelo com bom desempenho não diz se o resultado vem **do algoritmo** ou **dos dados**. Se onze algoritmos com pressupostos radicalmente diferentes — lineares, baseados em distância, em árvores, em margens, em redes neurais — chegam a desempenhos semelhantes, o teto observado é uma propriedade da informação disponível, não uma limitação de escolha técnica. Essa é a pergunta que esta seção responde.

Igualmente importante: **diferenças de desempenho entre modelos precisam de teste estatístico**. Comparar duas acurácias médias e declarar vencedor o maior número é um erro comum e sério. As estimativas vêm das mesmas partições de dados, são correlacionadas entre si, e um teste t comum aplicado a folds de validação cruzada infla drasticamente a taxa de falsos positivos. Por isso foi usado o **t corrigido de Nadeau-Bengio**, que ajusta a variância pela sobreposição entre conjuntos de treino, e o **McNemar**, que compara os modelos paciente a paciente em vez de média a média.

Glossário rápido dos testes usados:

Teste	O que responde	Como ler
t de Nadeau-Bengio	Dois modelos diferem em desempenho médio?	Corrige a dependência entre folds; $p < 0,05$ = diferença real
McNemar	Dois modelos erram nos <i>mesmos</i> pacientes?	Compara acertos exclusivos de cada um; p alto = empate técnico
DeLong	Duas curvas ROC diferem?	Teste específico para AUC pareado no mesmo conjunto
Qui-quadrado	O erro se concentra em algum grupo?	p baixo = o erro não é aleatório entre grupos
Mann-Whitney	Casos errados diferem dos acertados em alguma variável?	Compara distribuições sem assumir normalidade
Hosmer-Lemeshow	O risco previsto corresponde ao observado?	p baixo = modelo mal calibrado
Log-rank	Grupos de risco previstos têm sobrevida real distinta?	p baixo = a estratificação funciona na prática

2. Tarefa 1 — Classificação dos seis subtipos moleculares

2.1 Desempenho dos 11 algoritmos

Média de 15 partições (5-fold x 3 repetições), a partir dos 489 genes:

Modelo	Acurácia	DP	Acurácia balanceada	F1-macro
Gradient Boosting	0,7872	0,019	0,7256	0,7430
SVM RBF	0,7760	0,016	0,7241	0,7385
Random Forest	0,7663	0,021	0,6780	0,7021

Rede neural (MLP)	0,7591	0,017	0,7166	0,7266
Regressão logística (L2)	0,7582	0,021	0,7183	0,7265
Extra Trees	0,7563	0,023	0,6595	0,6818
LDA	0,7412	0,017	0,6895	0,7044
SVM linear	0,7401	0,020	0,7107	0,7127
Naive Bayes	0,7062	0,021	0,6968	0,6808
k-NN (k = 15)	0,6375	0,017	0,5584	0,5923
Baseline (classe majoritária)	0,3579	0,001	0,1667	0,0879

Leitura da acurácia balanceada. A acurácia simples é otimista quando as classes são desbalanceadas: o LumA sozinho representa 35,8% da coorte, e um modelo que sempre respondesse “LumA” já acertaria 35,8%. A acurácia balanceada é a média do acerto **dentro de cada classe**, e revela algo que a acurácia simples esconde: o Random Forest e o Extra Trees caem muito mais (0,678 e 0,660) do que a regressão logística (0,718), apesar de terem acurácia simples maior. Métodos baseados em árvores, sem reponderação de classes, favorecem as classes grandes.

2.2 O ranking é real? Os testes dizem que só em parte

t pareado corrigido de Nadeau-Bengio, tomando o Gradient Boosting como referência:

Comparação	Diferença de acurácia	t	p corrigido	Conclusão
vs. SVM RBF	+0,0112	1,19	0,254	empate estatístico
vs. Random Forest	+0,0209	1,79	0,095	empate estatístico
vs. Rede neural (MLP)	+0,0281	3,09	0,008	GB superior
vs. Regressão logística	+0,0290	2,69	0,018	GB superior
vs. Extra Trees	+0,0309	2,69	0,018	GB superior
vs. LDA	+0,0460	3,80	0,002	GB superior
vs. SVM linear	+0,0471	3,25	0,006	GB superior
vs. Naive Bayes	+0,0810	5,84	4×10^{-5}	GB superior
vs. k-NN	+0,1497	13,18	$< 10^{-8}$	GB superior
vs. Baseline	+0,4293	39,84	$< 10^{-15}$	GB superior

McNemar entre os dois primeiros colocados (Gradient Boosting vs. SVM RBF, sobre as 1.897 predições fora da amostra): 130 pacientes que só o Gradient Boosting acerta contra 114 que só o SVM RBF acerta; $\chi^2 = 0,922$; **p = 0,337**.

A conclusão é clara e vale ser dita sem rodeios: **o “vencedor” do ranking não é estatisticamente melhor que o segundo nem que o terceiro colocado**. A vantagem de 1,1 ponto percentual sobre o SVM RBF está dentro da flutuação amostral. Escolher o Gradient Boosting como modelo final é uma decisão legítima por outros critérios (velocidade, robustez a hiperparâmetros), mas não por superioridade demonstrada.

Por outro lado, três conclusões **são** estatisticamente sólidas: (i) todos os métodos superam massivamente o baseline; (ii) o k-NN é claramente inadequado para este problema — em 489 dimensões, a noção de “vizinho próximo” perde sentido, um efeito conhecido como maldição da dimensionalidade; (iii) modelos lineares (logística, LDA, SVM linear) ficam 3–5 pontos atrás dos não-lineares, indicando que existe estrutura de interação entre genes que os modelos lineares não capturam.

2.3 Onde exatamente o modelo erra

Matriz de confusão do Gradient Boosting (linhas = subtipo real, colunas = predito):

real predito	LumA	LumB	Her2	Basal	claudin-low	Normal
LumA	592	57	17	1	1	11
LumB	67	377	12	1	4	0
Her2	18	32	159	4	4	3
Basal	5	3	16	156	12	7
claudin-low	13	3	3	20	156	3
Normal	67	1	7	5	11	49

Métricas por classe:

Subtipo	Precisão	Recall	F1	n
LumA	0,777	0,872	0,822	679
LumB	0,797	0,818	0,807	461
Basal	0,834	0,784	0,808	199
claudin-low	0,830	0,788	0,808	198
Her2	0,743	0,723	0,733	220

Normal	0,671	0,350	0,460	140
--------	-------	-------	-------	-----

Prova de que o erro não é aleatório: qui-quadrado entre subtipo real e acerto/erro: $\chi^2 = 195,3$; $p = 2,9 \times 10^{-40}$. A taxa de acerto varia de 87,2% (LumA) a 35,0% (Normal).

O erro tem uma geometria. Todos os erros relevantes ocorrem entre pares **biologicamente adjacentes**: LumA ↔ LumB (124 erros nas duas direções), Her2 → LumB/LumA (50), Basal → Her2 (16), claudin-low → Basal (20), Normal → LumA (67). O que praticamente **não** acontece é igualmente informativo: apenas 5 casos Basal foram chamados de LumA e apenas 1 caso LumA foi chamado de Basal. **O modelo nunca confunde os extremos do espectro** — confunde vizinhos, exatamente onde a própria fronteira biológica é difusa.

2.4 Prova de que a maior falha é do rótulo, não do algoritmo

O subtipo “Normal-like” concentra o fracasso (recall 0,350; 67 dos 140 casos vão para LumA). Duas evidências independentes indicam que o problema está na natureza desse rótulo:

Evidência 1 — a celularidade tumoral prediz o erro. Testando se características da amostra se associam ao acerto (com correção FDR):

Variável	Teste	p	FDR	Associado ao erro?
Celularidade	qui-quadrado	0,0020	0,0111	sim
Integrative cluster	qui-quadrado	3×10^{-5}	0,0003	sim
Status de ER	qui-quadrado	0,0176	0,064	limítrofe
Tamanho tumoral	Mann-Whitney	0,050	0,137	não
Grau histológico	qui-quadrado	0,394	0,620	não
Status HER2	qui-quadrado	1,000	1,000	não
Idade ao diagnóstico	Mann-Whitney	0,512	0,701	não
Contagem de mutações	Mann-Whitney	0,573	0,701	não
Índice de Nottingham	Mann-Whitney	0,751	0,826	não

Taxa de acerto por celularidade: **alta 82,1%** (n = 936) → **moderada 76,6%** (n = 709) → **baixa 72,7%** (n = 198).

O gradiente é monótono e a interpretação é direta: quanto menor a fração de células tumorais na amostra, maior a contaminação por tecido mamário normal, e mais o perfil de expressão se afasta do tumor que se pretende classificar. **O modelo não está errando o cálculo — está recebendo, em parte, o transcriptoma do tecido errado.**

Evidência 2 — nada do que é clinicamente relevante prediz o erro. Grau, HER2, idade, NPI e carga mutacional têm FDR > 0,13. Se o modelo estivesse falhando por incapacidade de aprender, esperaríamos erro concentrado em tumores clinicamente difíceis. Não é o caso: **o erro segue a qualidade e a biologia da amostra, não a complexidade clínica do caso.**

2.5 O modelo sabe quando não sabe

Uma propriedade decisiva para uso prático: a confiança do modelo é informativa?

Confiança (probabilidade máxima) mediana nos acertos: **0,581**; nos erros: **0,442** — Mann-Whitney $p = 4,2 \times 10^{-60}$.

Faixa de confiança	n	Acerto observado	Confiança média
≤ 0,4	324	47,5%	0,341
0,4 - 0,5	449	68,6%	0,452
0,5 - 0,6	414	79,0%	0,548
0,6 - 0,7	350	89,7%	0,648
0,7 - 0,8	239	94,6%	0,747
0,8 - 0,9	106	98,1%	0,846
> 0,9	15	100,0%	0,925

A relação é monótona e a calibração é conservadora (o acerto real supera a confiança declarada em todas as faixas). Isso habilita uma estratégia operacional concreta: **classificar automaticamente os casos com confiança acima de 0,7 (acurácia ≥ 94,6%, 360 pacientes) e encaminhar à revisão os 324 casos abaixo de 0,4**, onde o modelo acerta pouco mais que uma moeda.

3. Tarefa 2 — Predição de óbito em até 10 anos

Coorte de 1.560 pacientes com desfecho de 10 anos determinado (702 óbitos, 45,0%), evitando censura informativa. Doze algoritmos × três conjuntos de variáveis = 36 combinações.

3.1 Ranking (AUC média em 15 partições)

Melhores de cada conjunto:

Conjunto	Melhor modelo	AUC	Brier
Clínico (6 variáveis)	Rede neural (MLP)	0,7356	0,207
Combinado	Gradient Boosting	0,7329	0,234
Genes (489)	Random Forest	0,6561	0,232

Ranking completo dos dez primeiros:

Posição	Conjunto Modelo	AUC
1	clínico Rede neural (MLP)	0,7356
2	combinado Gradient Boosting	0,7329
3	clínico SVM RBF	0,7271
4	clínico Random Forest	0,7258
5	combinado Logística LASSO	0,7226
6	clínico Extra Trees	0,7210
7	clínico Logística L2	0,7165
8	combinado Random Forest	0,7155
9	clínico LDA	0,7154
10	clínico SVM linear	0,7146

Oito das dez primeiras posições usam apenas as 6 variáveis clínicas. O melhor modelo genômico (0,656) fica na 21ª posição.

3.2 A prova estatística: os genes perdem em todos os algoritmos

Comparação pareada genes × clínico **dentro de cada algoritmo** (t de Nadeau-Bengio, correção FDR) — isso isola o efeito do conjunto de variáveis, eliminando o algoritmo como explicação:

Algoritmo	AUC genes	AUC clínico	Diferença	FDR
Rede neural (MLP)	0,614	0,736	−0,122	0,0003
k-NN	0,602	0,714	−0,112	0,0003
Logística L2	0,604	0,717	−0,112	0,0003
SVM linear	0,606	0,715	−0,109	0,0005
LDA	0,607	0,715	−0,109	0,0005
SVM RBF	0,655	0,727	−0,072	0,0021
Extra Trees	0,651	0,721	−0,070	0,0005
Random Forest	0,656	0,726	−0,070	0,0016
Naive Bayes	0,630	0,693	−0,064	0,0011
Gradient Boosting	0,638	0,700	−0,061	0,0025
Logística LASSO	0,654	0,714	−0,060	0,0006

Onze de onze algoritmos, todos com FDR < 0,003, na mesma direção. Não existe interpretação alternativa: a desvantagem dos 489 genes frente a 6 variáveis clínicas não é artefato de escolha de modelo, de linearidade, de regularização ou de hiperparâmetro. É uma propriedade dos dados.

Teste de DeLong (comparação formal de curvas ROC nas predições fora da amostra), tendo como referência o Gradient Boosting clínico (AUC 0,702):

Modelo	AUC	Diferença	z	p	FDR
clínico SVM RBF	0,731	+0,029	2,72	0,007	0,013
clínico Random Forest	0,730	+0,028	3,81	0,0001	0,0008
combinado Gradient Boosting	0,734	+0,032	2,59	0,010	0,014
genes Random Forest	0,656	−0,046	−2,70	0,007	0,013
genes SVM RBF	0,653	−0,049	−2,90	0,004	0,010
genes Gradient Boosting	0,643	−0,059	−3,43	0,0006	0,002
genes Logística L2	0,604	−0,099	−5,45	< 10 ^{−7}	< 10 ^{−6}

Observação central: acrescentar 489 genes ao modelo clínico **não melhora significativamente** o desempenho (combinado vs. clínico: +0,004, p = 0,82 no teste de Nadeau-Bengio) e, em vários algoritmos, **piora** — a logística combinada cai de 0,717 para 0,658. Isso é diluição de sinal: 489 preditores adicionais, quase todos sem informação prognóstica independente, aumentam a variância do modelo sem acrescentar sinal.

3.3 Onde o modelo acerta e onde falha, com intervalos de confiança

AUC por estrato do melhor modelo combinado, com IC 95% por bootstrap (1.500 reamostragens):

Estrato	n	Eventos	AUC	IC 95%	Melhor que acaso?
Coorte inteira	1.560	702	0,734	0,710 – 0,759	sim
LumA	544	183	0,772	0,728 – 0,815	sim
claudin-low	150	59	0,762	0,675 – 0,838	sim
Normal	111	52	0,759	0,656 – 0,849	sim
Her2	184	109	0,712	0,636 – 0,785	sim
LumB	394	204	0,671	0,620 – 0,722	sim
Basal	177	95	0,572	0,488 – 0,655	NÃO
Estágio I	390	113	0,679	0,622 – 0,737	sim
Estágio II	668	324	0,711	0,669 – 0,748	sim
Estágio III-IV	109	78	0,650	0,533 – 0,759	sim

O subtipo Basal é o único estrato onde o intervalo de confiança inclui 0,5. Essa é a demonstração formal — e não apenas a observação de um número baixo — de que o modelo **não funciona** em tumores basais. O IC 95% de 0,488 a 0,655 significa que, nesse grupo, não se pode rejeitar a hipótese de que a predição equivale ao acaso.

Taxa de acerto por subtipo ($\chi^2 = 27,48$; $p = 4,6 \times 10^{-5}$): LumA 73,3%, claudin-low 68,7%, Her2 67,4%, LumB 61,4%, Normal 61,3%, **Basal 55,4%**. Já por estágio, a diferença **não** é significativa ($\chi^2 = 4,55$; $p = 0,103$) — o modelo é razoavelmente estável entre estágios, e instável entre subtipos.

3.4 Que tipo de erro o modelo comete

Usando a mediana do risco previsto como ponto de corte (acurácia global 66,3%):

Resultado	n
Acerto: baixo risco / paciente viva	556
Acerto: alto risco / óbito	478
Falso positivo (alarme sem óbito)	302
Falso negativo (óbito não previsto)	224

Teste binomial: o modelo erra de forma assimétrica, com mais falsos positivos que falsos negativos (302 vs. 224; $p = 0,0008$). Em contexto de estratificação de risco, esse é o viés menos danoso — o modelo peca por cautela.

O perfil dos erros, com teste formal. Comparando os óbitos **não previstos** com os óbitos **previstos** (Mann-Whitney, todos com FDR < 0,001):

Variável	Óbito não previsto	Óbito previsto	FDR
Idade ao diagnóstico	61,3 anos	69,1 anos	< 0,001
Tamanho tumoral	20 mm	30 mm	< 0,001
Índice de Nottingham	4,04	5,04	< 0,001
Linfonodos positivos	0	2	< 0,001
Tempo até o óbito	70,1 meses	46,0 meses	< 0,001

Aqui está o retrato mais nítido da falha: **os óbitos que o modelo não antecipa são de pacientes mais jovens, com tumores menores, sem linfonodos comprometidos e índice prognóstico favorável — que morrem mais tarde dentro da janela de 10 anos.** Em outras palavras, o modelo captura bem a morte que “parece” provável pelos critérios clínicos clássicos e falha justamente nos casos que mais precisariam de um marcador molecular: pacientes com aparência clínica de baixo risco e evolução desfavorável. Esse é o nicho não atendido, e ele coincide exatamente com o resultado de que os genes não acrescentam sinal — se acrescentassem, seria aqui.

A composição do erro também depende do subtipo ($\chi^2 = 188,6$; $p = 4,3 \times 10^{-32}$). O grupo Normal-like tem a maior proporção de falsos negativos (25,2%), e Basal e LumB as maiores proporções de falsos positivos (28,8% e 24,9%).

3.5 Calibração: o risco previsto é confiável como número?

Faixa de risco previsto	n	Risco médio previsto	Óbito observado	Diferença
≤ 0,2	609	0,068	0,251	−0,183
0,2 – 0,3	120	0,253	0,367	−0,114
0,3 – 0,4	87	0,344	0,506	−0,162
0,4 – 0,5	110	0,452	0,436	+0,016
0,5 – 0,6	105	0,545	0,486	+0,060
0,6 – 0,7	91	0,649	0,571	+0,077
> 0,7	438	0,882	0,708	+0,174

Hosmer-Lemeshow: $\chi^2 = 779,4$; **gl = 8**; **p = $5,7 \times 10^{-163}$** . A calibração é **claramente ruim**, e de forma sistemática: o modelo é excessivamente confiante nos dois extremos. Entre as pacientes a quem atribui risco de 6,8%, morrem 25,1%; entre aquelas a quem atribui 88,2%, morrem 70,8%.

Isso tem consequência prática direta e merece destaque: **a ordenação de risco funciona, mas o número absoluto não pode ser comunicado como probabilidade**. Dizer a uma paciente “seu risco é de 7%” quando a taxa real no grupo é de 25% seria um erro clínico grave. Antes de qualquer uso, o modelo exigiria recalibração (Platt scaling ou regressão isotônica) — e é justamente por isso que uma métrica de discriminação como o AUC, isoladamente, é insuficiente para avaliar um modelo de risco.

3.6 A ordenação, essa sim, funciona

Dividindo a coorte em tercís pelo risco previsto e observando a sobrevida **real** (não a dicotomizada em 10 anos):

Tercil	n	Óbitos	Sobrevida global mediana
Baixo	520	246	227,9 meses
Médio	520	358	144,7 meses
Alto	520	433	74,5 meses

Log-rank: **p = $5,2 \times 10^{-61}$** . Uma diferença de **153 meses** — mais de doze anos — na sobrevida mediana entre os tercís extremos. Ou seja: apesar da calibração ruim e do AUC modesto, o modelo **ordena** as pacientes de forma extremamente significativa. Discriminação e calibração são propriedades distintas, e este modelo tem a primeira sem a segunda.

4. Síntese — o que ficou demonstrado

Sobre a comparação de algoritmos. Onze algoritmos com pressupostos distintos convergem para o mesmo teto: ~0,79 de acurácia na classificação de subtipos e ~0,73 de AUC na predição de sobrevida. As diferenças entre os três primeiros colocados **não são estatisticamente significativas** (Nadeau-Bengio $p \geq 0,095$; McNemar $p = 0,337$). A escolha do algoritmo não é o gargalo — a informação disponível é.

Sobre onde o modelo acerta. Classifica com alta confiabilidade os subtipos com identidade molecular definida (LumA recall 0,872; Basal e claudin-low F1 = 0,808) e ordena o risco de sobrevida de forma extremamente robusta (log-rank $p = 5 \times 10^{-61}$; 153 meses de diferença entre tercís extremos). Sabe reconhecer sua própria incerteza (confiança correlacionada com acerto, $p = 4 \times 10^{-60}$; 100% de acerto acima de 0,9 de confiança).

Sobre onde falha, e por quê. (i) O grupo Normal-like, com recall de 0,350, cuja falha se explica pela celularidade tumoral (FDR = 0,011) e não por características clínicas (todas com FDR > 0,13) — falha do rótulo, não do algoritmo. (ii) O subtipo Basal na predição de sobrevida, único estrato cujo IC 95% inclui o acaso (0,488–0,655). (iii) A calibração absoluta (Hosmer-Lemeshow $p = 6 \times 10^{-163}$), que impede comunicar o risco como probabilidade. (iv) Os óbitos de pacientes clinicamente favoráveis — mais jovens, tumores menores, sem linfonodos comprometidos (todos FDR < 0,001) —, que são exatamente os casos onde um marcador molecular seria mais valioso.

Sobre a expressão gênica como preditor de desfecho. Onze de onze algoritmos mostram os 489 genes inferiores às 6 variáveis clínicas, todos com FDR < 0,003 e na mesma direção; adicionar os genes ao modelo clínico não traz ganho ($p = 0,82$) e frequentemente prejudica. Este é o achado mais robusto de toda a análise, precisamente por ser independente de qualquer escolha metodológica.

5. Arquivos gerados

Arquivo	Conteúdo
M01, M02	Desempenho por partição e resumo dos 11 modelos (subtipo)
M03	Teste t corrigido de Nadeau-Bengio (subtipo)
M04, M05	Matriz de confusão e métricas por classe
M06	Predição individual por paciente (subtipo)
M07	Testes de associação entre características da amostra e erro
M08	Tabela de calibração da confiança
M10, M11	Desempenho por partição e resumo das 36 combinações (sobrevida)
M12	Teste t corrigido pareado (sobrevida)
M13	Comparação genes x clínico dentro de cada algoritmo
M14	Predições fora da amostra dos 12 melhores modelos
M15	Teste de DeLong
M16	Predição individual por paciente (sobrevida), com tipo de erro e tercil
M17	AUC por subtipo e estágio com IC 95% bootstrap
M18, M21	Perfil clínico dos erros e comparação óbito previsto x não previsto
M19	Medianas por tipo de resultado

Scripts: `ml_tarefa1_subtipo.py`, `ml_tarefa2_sobrevida.py`, `ml_tarefa2_final.py`. Semente 42 em todas as etapas; resultados integralmente reproduzíveis.