

Pipeline METABRIC em R relatório de execu o

- [Genes associados a subtipos moleculares e a pior prognóstico no câncer de mama](#)
 - [Relatório final da pipeline analítica em R — coorte METABRIC \(n = 1.897\)](#)
 - [1. Sumário executivo](#)
 - [2. Dados: origem, proveniência e integridade](#)
 - [3. Ambiente computacional e bibliotecas](#)
 - [4. Metodologia](#)
 - [5. Resultados](#)
 - [6. Resposta direta à pergunta da análise](#)
 - [7. Limitações](#)
 - [8. Dicionário completo das saídas geradas](#)
 - [9. Como reproduzir](#)
 - [10. Próximos passos sugeridos](#)
 - [11. Referências](#)

Genes associados a subtipos moleculares e a pior prognóstico no câncer de mama

Relatório final da pipeline analítica em R — coorte METABRIC (n = 1.897)

Data da execução: 06/08/2026 · **Ambiente:** R 4.3.3 (2024-02-29), Ubuntu 24.04 · **Tempo total de execução:** 6,57 min · **Semente global:** 42

1. Sumário executivo

Foi construída e executada uma pipeline reprodutível em R, de ponta a ponta, sobre **dados reais e não simulados** da coorte METABRIC (Molecular Taxonomy of Breast Cancer International Consortium). A análise integrou expressão gênica (489 genes, z-scores de microarranjo), status mutacional (173 genes) e desfechos de sobrevida de 1.897 pacientes com seguimento mediano de 115,6 meses (1.098 óbitos por qualquer causa; 619 óbitos atribuídos ao câncer de mama).

Achados centrais:

1. **Os subtipos moleculares diferem fortemente em prognóstico** (log-rank global $p = 3,7 \times 10^{-10}$). A sobrevida global mediana variou de 219,2 meses (claudin-low) a 104,0 meses (Her2).
2. **568 associações gene-subtipo** atingiram significância ($FDR < 0,01$ e $|\Delta z| \geq 0,50$), com assinaturas biologicamente coerentes: *ERBB2* no Her2; *CCNE1*, *CDKN2A*, *CHEK1*, *E2F3* no Basal; *GATA3*, *MAPT*, *BCL2* no LumA; *FOLR2*, *KLRG1*, *CSF1R*, *CSF1R/TGFB2* (assinatura imune-estromal) com perda de *ERBB3/RAB25* no claudin-low.
3. **125 genes** associaram-se independentemente à sobrevida global e **137** à sobrevida específica por câncer ($FDR < 0,05$). Os efeitos mais robustos, mantidos após ajuste por idade, grau, tamanho, linfonodos, subtipo e tratamentos, foram *STAT5A* (HR ajustado 0,867), *GSK3B* (1,133), *VEGFA* (1,125), *BCL2* (0,885) e *AURKA* (1,107).
4. **A assinatura multigênica derivada por LASSO-Cox não superou o modelo clínico:** em 25 partições independentes, C-index médio de 0,555 (assinatura) versus 0,655 (clínico), e o modelo combinado não acrescentou discriminação sobre o clínico (diferença média +0,0003; Wilcoxon pareado $p = 0,70$). Esse resultado negativo é relatado explicitamente porque contradiz a leitura ingênua do teste de razão de verossimilhança feito na amostra de derivação ($\chi^2 = 161,5$; $p = 5,3 \times 10^{-37}$) — a discrepância é a assinatura digital do sobreajuste.
5. **Mutações somáticas segregam nitidamente por subtipo:** *TP53* em 88,4% dos Basal e 70,0% dos Her2 contra 11,9% dos LumA; *PIK3CA* em 57,4% dos LumA contra 16,1% dos Basal (ambos $FDR = 5,1 \times 10^{-4}$). Mutação em *GATA3* associou-se a melhor sobrevida (HR 0,590; $FDR 3,3 \times 10^{-5}$) e em *TP53* a pior (HR 1,289; $FDR 1,3 \times 10^{-3}$).

2. Dados: origem, proveniência e integridade

Item	Valor
Estudo	METABRIC / cBioPortal <code>brca_metabric</code>
Publicações originais	Curtis et al., <i>Nature</i> 486:346-352 (2012); Pereira et al., <i>Nat Commun</i> 7:11479 (2016)
Arquivo processado	<code>METABRIC_RNA_Mutation.csv</code> (recorte curado do cBioPortal)
Checksum MD5 verificado na pipeline	<code>c619471beb87af0f9fd4e4a4a0058654d</code>
Pacientes no arquivo bruto	1.904
Colunas	693 (31 clínicas + 489 expressão + 173 mutação)

IDs duplicados	0
Valores ausentes na matriz de expressão	0
Faixa dos z-scores	−7,2432 a +20,3950
Plataforma de expressão	Illumina HT-12 v3 (microarranjo), z-scores calculados pelo cBioPortal
Plataforma mutacional	sequenciamento alvo de painel de genes drivers

Natureza dos dados. Nenhum valor foi simulado, imputado por modelo ou gerado sinteticamente. O único tratamento aplicado a valores ausentes foi a exclusão por caso (*complete-case*) nos modelos que exigiam covariáveis clínicas.

2.1 Auditoria da codificação do desfecho (etapa crítica)

Esse conjunto de dados é frequentemente analisado com o evento invertido. A pipeline audita a codificação antes de qualquer modelagem (tabela T02):

overall_survival	Died of Disease	Died of Other Causes	Living
0	622	480	0
1	0	0	801

Ou seja, overall_survival = 1 significa **paciente vivo**. Definições adotadas:

- OS (sobrevida global):** evento = 1 − overall_survival → 1.098 óbitos.
- DSS (sobrevida específica do câncer):** evento = 1 se death_from_cancer == "Died of Disease"; óbitos por outras causas são **censurados** (não tratados como evento) → 619 eventos. Um paciente sem informação de causa permaneceu como NA e foi excluído apenas das análises de DSS.

2.2 Fluxograma de exclusões

Etapas	Excluídos	Restantes
Coorte inicial	—	1.904
Histologia não mamária (Breast Sarcoma)	1	1.903
Subtipo PAM50/claudin-low = "NC" (não classificado)	6	1.897
Tempo de seguimento ausente ou ≤ 0	0	1.897
Coorte analítica final	—	1.897

3. Ambiente computacional e bibliotecas

O script instala automaticamente qualquer biblioteca ausente (CRAN + Bioconductor) antes de iniciar a análise — ver seção 9. As versões efetivamente utilizadas nesta execução ficam registradas em T28_bibliotecas_versoes.csv e em saidas/logs/sessionInfo.txt.

Pacote	Versão	Finalidade específica nesta pipeline
data.table	1.14.10	Leitura de alto desempenho (fread) do CSV de 8,1 MB e escrita de todas as 33 tabelas de saída (fwrite)
dplyr	1.1.4	Manipulação tabular: filtros, agrupamentos e sumarizações da caracterização clínica e das tabelas de integração
tidyr	1.3.1	Conversão wide↔long (pivot_longer) para os heatmaps de mutação e para o boxplot de C-index
purrr	1.0.2	Iteração funcional (map_dfr) sobre os 489 genes nos modelos de Cox e sobre os contrastes de subtipo
stringr	1.5.1	Normalização de nomes de genes e rótulos de figuras
forcats	1.0.0	Ordenação de fatores em gráficos (fct_reorder) e definição da ordem dos subtipos
limma	3.58.1	Núcleo da expressão diferencial: modelos lineares por gene com moderação bayesiana empírica da variância (lmFit , contrasts.fit , eBayes)
survival	3.5-8	Objetos Surv , estimador de Kaplan-Meier, teste log-rank (survdiff), modelos de Cox (coxph), teste de riscos proporcionais (cox.zph) e cálculo de concordância (concordance)
survminer	0.4.9	Curvas de sobrevivência com tabela de números sob risco e valor-p do log-rank (ggsurvplot)
glmnet	4.1-8	Regressão de Cox penalizada por LASSO com validação cruzada (cv.glmnet , family = "cox") para derivação da assinatura multigênica
randomForest	4.7-11	Classificação multiclasse dos subtipos e ranqueamento multivariado de importância dos genes

pacote	versão	funcionamento mantido ou importância dos genes (Gini e queda de acurácia)
matrixStats	1.2.0	Estatísticas por linha da matriz de expressão (desvio-padrão, MAD, mínimo, máximo) no controle de qualidade
broom	1.0.5	Padronização de saídas de modelos em <code>data.frame</code>
ggplot2	3.4.4	Motor gráfico de todas as 13 figuras
ggrepel	0.9.5	Rótulos de genes sem sobreposição nos volcano plots e no gráfico de integração
scales	1.3.0	Formatação de eixos (escala $\log_2$ do forest plot)
RColorBrewer	1.1-3	Paleta divergente RdBu do heatmap e paletas categóricas dos subtipos
viridis	0.6.5	Escalas contínuas perceptualmente uniformes (importância do RF, frequências de mutação)
pheatmap	1.0.12	Heatmap com clusterização hierárquica dos genes discriminantes
patchwork	1.2.0	Composição de painéis múltiplos em uma única figura
cowplot	1.1.3	Tema gráfico consistente e alinhamento de painéis
gridExtra	2.3	Manipulação de objetos grid na exportação das figuras

4. Metodologia

A pipeline está organizada em 12 módulos sequenciais no arquivo `metabric_pipeline.R` (764 linhas, integralmente comentado em português). Parâmetros analíticos foram declarados *a priori* em um único objeto `PAR`, evitando escolhas post-hoc: FDR < 0,01 e $|\Delta z| \geq 0,50$ para expressão diferencial; FDR < 0,05 para Cox; 70/30 para partição; 500 árvores no Random Forest; 10 dobras na validação cruzada; frequência mínima de 2% para testar mutações.

Módulo 0 — Ambiente. Carregamento de bibliotecas, semente fixa (42), definição de diretórios e funções auxiliares de exportação.

Módulo 1 — Ingestão e integridade. Leitura do CSV, identificação automática dos blocos de colunas (clínicas, expressão, `*_mut`), verificação de duplicatas, ausentes, faixa de valores e checksum MD5.

Módulo 2 — QC e pré-processamento. Auditoria da codificação do desfecho (seção 2.1), aplicação dos critérios de exclusão, padronização de covariáveis clínicas, montagem da matriz genes $\times$ amostras (489 $\times$ 1.897) e binarização das colunas mutacionais (0 = selvagem; qualquer variante = mutado).

Módulo 3 — Caracterização clínica. Estatísticas descritivas por subtipo; associação com variáveis categóricas por qui-quadrado de Pearson e com variáveis contínuas por Kruskal-Wallis (não paramétrico, sem assumir normalidade), com correção de Benjamini-Hochberg (BH).

Módulo 4 — Expressão diferencial (limma). Modelo linear sem intercepto (`~ 0 + subtipo`) com contrastes **um-vs-demais** para cada um dos 6 subtipos, isto é, cada subtipo contra a média dos outros cinco. Moderação bayesiana empírica com `trend = TRUE` e `robust = TRUE`; ajuste BH. Como a expressão já está em z-score, o coeficiente do contraste (Δz) é diretamente interpretável como diferença em desvios-padrão — um tamanho de efeito, não apenas um p-valor.

Módulo 5 — Random Forest. Classificação dos 6 subtipos a partir dos 489 genes (500 árvores), com erro out-of-bag como estimativa honesta de generalização e ranqueamento de importância (queda média de Gini e de acurácia). Serve como verificação multivariada e não-linear do que o limma detecta gene a gene.

Módulo 6 — Cox univariado gene a gene. 489 modelos de Cox para OS e 489 para DSS, com a expressão em z-score, de modo que o HR expressa o risco por **aumento de 1 desvio-padrão** de expressão. Correção BH. Para os 20 genes mais fortes: teste formal do pressuposto de riscos proporcionais (`cox.zph`) e reanálise em modelo multivariável ajustado por idade, grau, tamanho tumoral, status linfonodal, subtipo, quimioterapia, hormonioterapia e radioterapia.

Módulo 7 — Kaplan-Meier e análise estratificada. Curvas por subtipo e por expressão dicotomizada na mediana (com a ressalva metodológica de que dicotomizar variáveis contínuas reduz poder — usada aqui apenas para visualização, enquanto a inferência permanece nos modelos contínuos). Cox dentro de cada subtipo para os 12 genes mais prognósticos, testando se o efeito é global ou dependente do contexto molecular.

Módulo 8 — Assinatura multigênica (LASSO-Cox). Partição estratificada 70/30 preservando a distribuição conjunta de subtipo e evento; `cv.glmnet` com 10 dobras; extração dos coeficientes em `lambda.min` e `lambda.1se`; escore de risco linear; comparação de C-index entre modelo gênico, clínico e combinado; teste de razão de verossimilhança; estratificação em tercís de risco definidos **no conjunto de derivação** e aplicados ao de validação.

Módulo 8b — Estabilidade e validação repetida. Como uma única partição 70/30 produz estimativas instáveis, todo o procedimento (partição $\rightarrow$ `cv.glmnet` $\rightarrow$ avaliação) foi repetido **25 vezes** com sementes distintas, registrando a distribuição do C-index dos três modelos, comparações pareadas por Wilcoxon e a frequência de seleção de cada gene (*stability selection*).

Módulo 9 — Mutações somáticas. Dos 173 genes, 71 atingiram frequência $\geq 2\%$ e foram testados: teste exato de Fisher (com p simulado por Monte Carlo, B = 20.000, para tabelas 2 $\times$ 6) para heterogeneidade entre subtipos, e Cox univariado para associação

com OS; ambos com correção BH.

Módulo 10 — Integração. Cruzamento das camadas: genes simultaneamente marcadores de subtipo ($FDR < 0,01$, $|\Delta z| \geq 0,50$) e prognósticos ($FDR < 0,05$), classificados quanto à **coerência direcional** (se o gene está superexpresso no subtipo e sua alta expressão prediz maior risco, é marcador de pior prognóstico naquele subtipo). Escore de prioridade = $|\Delta z| \times |\log HR| \times -\log_{10}(FDR_OS)$, com anotação da posição no ranking do Random Forest e do coeficiente LASSO.

5. Resultados

5.1 Caracterização clínica por subtipo (T05, T06, F01)

Subtipo	n (%)	Idade mediana	Tamanho (mm)	G3 (%)	N+ (%)	ER+ (%)	HER2+ (%)	NPI	Óbitos (%)	Óbitos por câncer
LumA	679 (35,8)	63,2	20,5	25,9	42,3	99,6	3,1	3,08	53,6	146
LumB	461 (24,3)	66,2	25,0	55,6	51,4	100,0	9,1	4,05	65,7	181
Her2	220 (11,6)	58,8	25,0	73,7	57,3	42,3	56,8	4,08	70,5	107
Basal	199 (10,5)	54,5	25,0	90,5	53,8	13,6	10,1	5,02	55,8	81
claudin-low	198 (10,4)	58,5	20,0	67,9	47,5	38,4	7,6	4,05	44,9	56
Normal	140 (7,4)	57,8	23,0	34,1	40,0	85,7	9,3	4,03	54,3	48

Todas as 14 variáveis clínicas testadas diferiram significativamente entre subtipos após correção BH (T06). As associações mais fortes: status de ER ($\chi^2 = 1.093,9$; $FDR = 4,0 \times 10^{-233}$), grau histológico ($\chi^2 = 403,8$; $FDR = 5,1 \times 10^{-80}$), PR ($FDR = 3,9 \times 10^{-106}$), HER2 ($FDR = 2,8 \times 10^{-97}$) e NPI (Kruskal-Wallis, $FDR = 8,2 \times 10^{-46}$). O subtipo Basal concentra pacientes mais jovens (mediana 54,5 anos), tumores G3 (90,5%) e o maior NPI (5,02).

5.2 Sobrevida global por subtipo (T16, F06)

Subtipo	n	Óbitos	Mediana de OS (meses)	IC 95%
claudin-low	198	89	219,2	194,1 - 238,1
LumA	679	364	186,6	169,0 - 198,1
Normal	140	76	158,5	125,8 - 203,5
Basal	199	111	130,9	83,4 - 206,6
LumB	461	303	123,0	114,9 - 143,1
Her2	220	155	104,0	88,9 - 142,4

Teste log-rank global: χ^2 correspondente a **$p = 3,74 \times 10^{-10}$** .

Observação relevante: no METABRIC, coorte majoritariamente pré-trastuzumabe, o subtipo **Her2 apresenta a pior sobrevida mediana**, e o Basal — apesar do perfil clínico mais agressivo — não se destaca como o pior em sobrevida global de longo prazo, refletindo o padrão bem descrito de risco precoce elevado seguido de platô, enquanto os luminais mantêm risco tardio persistente. Isso também explica por que o pressuposto de riscos proporcionais é problemático nesta coorte (seção 5.5).

5.3 Expressão diferencial por subtipo (T07-T09, F02, F03)

568 associações gene-subtipo significativas ($FDR < 0,01$ e $|\Delta z| \geq 0,50$):

Subtipo	Significativos por FDR	Com efeito $\geq 0,50$	Superexpressos	Subexpressos
Basal	300	151	89	62
claudin-low	269	107	62	45
LumB	308	92	33	59
Normal	201	78	38	40
LumA	287	77	30	47
Her2	248	63	36	27

Principais marcadores por subtipo (Δz ; todos com $FDR \ll 0,01$):

- **Basal** — *CCNE1* (+1,67), *CDKN2A* (+1,66), *CHEK1* (+1,57), *MAP2* (+1,53), *E2F3* (+1,51), *TTYH1* (+1,49), *CDC25A* (+1,45); *TGFB3* (−1,41). Assinatura clássica de desregulação do ciclo celular G1/S e resposta a dano de DNA.
- **Her2** — *ERBB2* (+1,57), *ARRDC1* (+1,12), *GSK3B* (+1,04), *MMP15* (+1,02), *AKT1* (+0,99); *SMAD4* (−1,11), *MYC* (−0,98), *BCL2* (−0,96). A superexpressão de *ERBB2* funciona como controle positivo interno da pipeline.
- **LumA** — *GATA3* (+1,13), *MAPT* (+1,12), *APH1B* (+0,94), *BCL2* (+0,91); *AURKA* (−0,96), *CCNE1* (−0,94), *E2F2* (−0,93), *CHEK1* (−0,92). Perfil de baixa proliferação com diferenciação luminal preservada.
- **LumB** — *GATA3* (+1,00); *EGFR* (−1,06), *LAMB3* (−0,94), *NOTCH1* (−0,94), *PLAGL1* (−0,92), *FOXO1* (−0,90), *SPRY2* (−0,90), *MMP7* (−0,88). Identidade luminal com perda de reguladores negativos de crescimento.
- **claudin-low** — *FOLR2* (+1,57), *KLRG1* (+1,56), *CSF1R* (+1,37), *TGFBR2* (+1,27), *CCND2* (+1,26), *ACVRL1* (+1,19); *ERBB3* (−1,51), *RAB25* (−1,42). Assinatura imune/estromal (macrófagos, linfócitos) com perda de identidade epitelial —

- exatamente o fenótipo mesenquimal que define esse grupo.
- **Normal** — *NR2F1* (+1,05), *ABCB1* (+1,02), *SPRY2* (+0,98), *LAMA2* (+0,98); *CDK1* (−1,04), *CHEK1* (−0,97), *AURKA* (−0,94).

5.4 Classificação por Random Forest (T10, T11, F04)

Erro out-of-bag global: **23,77%** (acurácia ≈ 76%) na discriminação de 6 classes a partir de 489 genes. Erro por classe:

Subtipo	Erro de classificação
LumA	11,3%
LumB	18,0%
Basal	20,6%
claudin-low	29,8%
Her2	35,5%
Normal	80,7%

O erro de 80,7% no grupo “Normal-like” é um resultado informativo, não um defeito do modelo: 93 dos 140 casos são classificados como LumA. Isso é consistente com a literatura que questiona se o Normal-like é uma entidade biológica ou um artefato de baixa celularidade tumoral com contaminação por tecido mamário normal. A confusão residual Her2 → LumA/LumB (76 casos) reflete a sobreposição entre HER2 clínico e subtipo intrínseco.

5.5 Genes associados à sobrevida (T12-T15, F05)

125 genes com FDR < 0,05 para OS e **137** para DSS. Top 15 para sobrevida global (HR por +1 DP de expressão):

Gene	HR	IC 95%	FDR
GSK3B	1,225	1,16–1,29	$3,8 \times 10^{-10}$
STAT5A	0,807	0,76–0,86	$1,7 \times 10^{-9}$
SPRY2	0,810	0,76–0,86	$2,6 \times 10^{-8}$
IGF1	0,804	0,75–0,86	$1,0 \times 10^{-7}$
ABCB1	0,822	0,77–0,88	$2,6 \times 10^{-7}$
AURKA	1,191	1,12–1,26	$2,6 \times 10^{-7}$
LAMA2	0,836	0,79–0,89	$2,6 \times 10^{-7}$
FLT3	0,820	0,77–0,88	$2,6 \times 10^{-7}$
STAT5B	0,838	0,79–0,89	$4,9 \times 10^{-7}$
CDKN2C	0,815	0,76–0,87	$5,0 \times 10^{-7}$
PDGFRA	0,844	0,80–0,89	$6,2 \times 10^{-7}$
RPS6	0,855	0,81–0,90	$1,6 \times 10^{-6}$
CCND2	0,846	0,80–0,90	$2,3 \times 10^{-6}$
BCL2	0,849	0,80–0,90	$5,0 \times 10^{-6}$
VEGFA	1,165	1,10–1,23	$5,8 \times 10^{-6}$

Para o desfecho específico do câncer (DSS), os efeitos são **maiores em magnitude**, como esperado ao remover o ruído da mortalidade competitiva: *AURKA* HR 1,458 (FDR $1,5 \times 10^{-20}$), *BCL2* 0,723, *MAPT* 0,735, *GSK3B* 1,326, *FANCD2* 1,323, *E2F2* 1,310, *CCNE1* 1,271.

Ajuste por covariáveis clínicas (idade, grau, tamanho, linfonodos, subtipo, quimio, hormônio, radioterapia). Dos 20 genes testados, 10 mantiveram significância após correção BH:

Gene	HR ajustado	IC 95%	FDR
STAT5A	0,867	0,81–0,93	$5,8 \times 10^{-4}$
GSK3B	1,133	1,06–1,21	$2,5 \times 10^{-3}$
VEGFA	1,125	1,05–1,20	$2,5 \times 10^{-3}$
BCL2	0,885	0,82–0,96	0,015
CDKN2C	0,896	0,83–0,97	0,018
CIR1	0,911	0,85–0,97	0,018
STAT5B	0,912	0,85–0,98	0,021
IGF1	0,910	0,84–0,98	0,038
AURKA	1,107	1,02–1,20	0,038
FLT3	0,923	0,86–0,99	0,038

A atenuação dos HR (por exemplo, *GSK3B* de 1,225 para 1,133) mostra que parte do efeito univariado é mediada pelo subtipo e pelo grau — mas não toda, o que caracteriza informação prognóstica parcialmente independente.

Alerta metodológico (T14). Entre os 20 genes mais prognósticos, **12 violaram o pressuposto de riscos proporcionais**

(*cox.zph* , $p < 0,05$) e apenas 8 o atenderam. Com seguimento mediano de quase 10 anos, isso é esperado: o efeito de vários genes é forte nos primeiros anos e se dilui depois. Consequência prática: os HR reportados devem ser lidos como **efeitos médios ao longo do seguimento**, não como razões de risco constantes. Modelagem com efeitos dependentes do tempo ou restrição da janela de análise (por exemplo, OS em 5 anos) é a extensão natural desta pipeline.

5.6 Kaplan-Meier por expressão gênica (T17, F07)

Gene	Mediana OS — expressão baixa	Mediana OS — expressão alta	Log-rank p
GSK3B	186,4 meses	124,8 meses	$2,8 \times 10^{-10}$
STAT5A	124,8 meses	187,9 meses	$2,5 \times 10^{-10}$
SPRY2	139,3 meses	174,6 meses	$7,6 \times 10^{-6}$
IGF1	137,9 meses	176,3 meses	$1,4 \times 10^{-5}$

Alta expressão de *GSK3B* está associada a uma perda de aproximadamente **61 meses** de sobrevida mediana; alta expressão de *STAT5A*, a um ganho de aproximadamente **63 meses**.

5.7 Efeito prognóstico dentro de cada subtipo (T18, F08)

Este é um dos resultados mais informativos da análise. Testando os 12 genes mais prognósticos dentro de cada subtipo:

- **LumA** (679 pacientes, 364 eventos) — **todos os 12 genes** foram significativos, e os efeitos são maiores do que na coorte inteira: *PDGFRA* HR 0,695 ($p = 5,4 \times 10^{-11}$), *SPRY2* 0,692, *CDKN2C* 0,746, *STAT5A* 0,757, *ABCB1* 0,741, *GSK3B* 1,273.
- **LumB** (461, 303 eventos) — 4 genes significativos: *GSK3B* 1,304, *FLT3* 0,798, *STAT5A* 0,829, *IGF1* 0,807.
- **Normal** (140, 76 eventos) — *AURKA* HR 1,835 ($p = 5,8 \times 10^{-4}$), *GSK3B* 1,388, *STAT5B* 0,674, *FLT3* 0,648.
- **claudin-low** (198, 89 eventos) — efeitos fracos, nenhum sobrevivendo à correção FDR.
- **Her2 e Basal** — **nenhum gene significativo**.

Interpretação: a informação prognóstica transcricional se concentra nos tumores **luminais**, onde existe heterogeneidade de risco a ser resolvida. Nos subtipos Her2 e Basal, o próprio subtipo já determina a maior parte do risco e a expressão desses genes acrescenta pouco — o que tem consequência direta para o desenho de painéis prognósticos: um painel derivado da coorte inteira será, na prática, um painel para doença luminal.

5.8 Assinatura multigênica e sua validação (T19-T22, T29-T32, F09, F10, F13)

O LASSO-Cox selecionou **65 genes** em `lambda.min` e **12 genes** em `lambda.1se`. Os maiores coeficientes em `lambda.min`: *HSD3B7* (−0,115), *CDKN2A* (−0,103), *CDKN2C* (−0,093), *FLT3* (−0,084), *MMP25* (−0,083), *SMAD6* (+0,080), *GSK3B* (+0,075). A assinatura parcimoniosa (`lambda.1se`) é: *FLT3*, *CDKN2C*, *SMAD6*, *STAT5A*, *GSK3B*, *MMP25*, *VEGFA*, *ABCB1*, *SPRY2*, *IGF1*, *CTCF*, *PDGFRA*.

Desempenho em partição única (T20):

Modelo	Genes	C-index derivação	C-index validação
Assinatura LASSO (<code>lambda.min</code>)	65	0,683	0,588
Assinatura LASSO (<code>lambda.1se</code>)	12	0,623	0,585
Clínico	—	0,657	0,661
Combinado (<code>lambda.min</code>)	65	0,711	0,651
Combinado (<code>lambda.1se</code>)	12	0,675	0,667

Desempenho em 25 partições independentes (T30, T31):

Modelo	C-index médio	DP	Mín	Máx
Assinatura gênica	0,5549	0,0354	0,500	0,611
Clínico	0,6553	0,0139	0,627	0,689
Combinado	0,6556	0,0142	0,634	0,691

Comparações pareadas (Wilcoxon): combinado vs. clínico → diferença média **+0,0003**, **p = 0,70** (sem ganho); assinatura vs. clínico → **−0,1004**, **p = 6×10^{-8}** (a assinatura é inferior).

Este é o resultado mais importante do relatório em termos metodológicos. Na amostra de derivação, o teste de razão de verossimilhança indica que a assinatura acrescenta informação de forma espetacular ($\chi^2 = 161,5$; 1 gl; $p = 5,3 \times 10^{-37}$). Fora da amostra, esse ganho **desaparece por completo**. A explicação: com 489 candidatos e ~1.100 eventos, o LASSO captura estrutura específica da amostra de treino; além disso, o subtipo molecular já está no modelo clínico e ele próprio é um resumo da expressão gênica — a assinatura, em grande parte, apenas reexpressa informação já contida no subtipo e no grau. Relatar apenas o valor-p intra-amostral produziria a conclusão oposta e falsa.

A estratificação em tercís reproduz o mesmo padrão: na derivação a separação é ampla (33,8% / 60,5% / 79,6% de óbitos), mas na validação ela se comprime (48,5% / 61,1% / 64,7%).

Estabilidade de seleção (T32, F13B). Nas 25 repetições, apenas quatro genes foram selecionados com alguma consistência: **GSK3B (72%)**, **STAT5A (60%)**, *FLT3* (32%) e *SPRY2* (32%). Todos os demais ficaram em $\leq 12\%$. Ou seja, a lista de 65 genes é em grande parte instável — mas o núcleo *GSK3B* / *STAT5A* é reproduzível e coincide com os achados do Cox univariado e ajustado.

Esse é o subconjunto que merece investigação subsequente.

5.9 Mutações somáticas (T23, T24, F11)

Dos 173 genes com dado mutacional, 71 alcançaram frequência ≥ 2%. Distribuição por subtipo dos principais (todos com FDR ≤ 5,1 × 10⁻⁴):

Gene	Global	LumA	LumB	Her2	Basal	claudin-low	Normal
PIK3CA	41,8%	57,4%	34,9%	41,4%	16,1%	24,2%	50,0%
TP53	34,7%	11,9%	24,3%	70,0%	88,4%	52,0%	22,9%
MUC16	17,2%	16,6%	16,1%	27,3%	23,1%	9,6%	10,0%
GATA3	12,1%	19,6%	13,9%	7,7%	0,0%	2,0%	8,6%
MAP3K1	10,3%	16,2%	8,7%	6,8%	4,5%	4,0%	10,0%
CDH1	9,1%	12,7%	9,8%	5,0%	2,0%	4,0%	12,9%
CBFB	4,8%	8,4%	3,7%	0,9%	0,5%	2,5%	6,4%
RB1	2,6%	1,5%	2,4%	3,2%	7,0%	3,5%	0,0%

O eixo *TP53*-mutado/*PIK3CA*-selvagem (Basal, Her2) versus *PIK3CA*-mutado/*TP53*-selvagem (LumA) reproduz com precisão a dicotomia estabelecida na literatura de câncer de mama — uma validação externa implícita da pipeline.

Associação com sobrevida global (Cox univariado):

Gene mutado	Frequência	HR	IC 95%	FDR
GATA3	12,1%	0,590	0,48–0,72	3,3 × 10 ⁻⁵
CBFB	4,8%	0,501	0,36–0,70	1,3 × 10 ⁻³
TP53	34,7%	1,289	1,14–1,46	1,3 × 10 ⁻³

Nenhum outro gene mutado sobreviveu à correção BH. Ressalva importante: mutação em *GATA3* e *CBFB* concentra-se em tumores LumA, e mutação em *TP53* em Basal/Her2 — de modo que esses HR são **fortemente confundidos pelo subtipo** e não devem ser lidos como efeito causal independente sem modelagem estratificada.

5.10 Integração: subtipo × prognóstico (T25, T26, F12)

O cruzamento produziu **223 pares gene-subtipo** que são simultaneamente marcadores de subtipo e prognósticos. Os prioritários por subtipo (escore = |Δz| × |log HR| × −log₁₀ FDR):

Subtipo	Genes prioritários	Leitura
Basal	<i>AURKA</i> (↑, HR 1,19), <i>FANCD2</i> (↑, HR 1,16), <i>IGF1</i> (↓, HR 0,80), <i>LAMA2</i> (↓, HR 0,84), <i>BCL2</i> (↓, HR 0,85)	Todos coerentes com pior prognóstico : o Basal superexpressa genes de risco e perde genes protetores
Her2	<i>GSK3B</i> (↑, HR 1,23), <i>SPRY2</i> (↓), <i>LAMA2</i> (↓), <i>BCL2</i> (↓), <i>STAT5B</i> (↓)	Padrão de pior prognóstico dominado pela superexpressão de <i>GSK3B</i>
LumB	<i>SPRY2</i> (↓), <i>ABCB1</i> (↓), <i>STAT5A</i> (↓), <i>PDGFRA</i> (↓), <i>CCND2</i> (↓)	Pior prognóstico por perda de genes protetores , não por ganho de genes de risco
LumA	<i>AURKA</i> (↓), <i>BCL2</i> (↑), <i>FANCD2</i> (↓), <i>E2F7</i> (↓), <i>E2F2</i> (↓)	Perfil de melhor prognóstico — o espelho exato do Basal
claudin-low	<i>STAT5A</i> (↑), <i>ABCB1</i> (↑), <i>IGF1</i> (↑), <i>CDKN2C</i> (↑), <i>CCND2</i> (↑)	Melhor prognóstico, consistente com a maior sobrevida mediana observada
Normal	<i>SPRY2</i> (↑), <i>ABCB1</i> (↑), <i>LAMA2</i> (↑), <i>AURKA</i> (↓), <i>KIT</i> (↑)	Melhor prognóstico

Note a simetria entre Basal e LumA: os mesmos genes (*AURKA*, *FANCD2*, *E2F2*, *BCL2*) aparecem nos dois, com direções invertidas. Isso indica que o eixo prognóstico dominante na coorte não é um conjunto de genes independentes, mas um **gradiente único de proliferação** — o que também explica por que a assinatura LASSO acrescenta tão pouco ao modelo que já contém subtipo e grau.

6. Resposta direta à pergunta da análise

Quais genes estão mais associados a determinados subtipos? *ERBB2* (Her2); *CCNE1*, *CDKN2A*, *CHEK1*, *E2F3*, *CDC25A* (Basal); *GATA3*, *MAPT*, *BCL2* (LumA); *FOLR2*, *KLRG1*, *CSF1R*, *TGFBR2* com perda de *ERBB3/RAB25* (claudin-low); perda de *EGFR*, *NOTCH1*, *FOXO1*, *SPRY2* (LumB). No plano mutacional: *TP53* (Basal, Her2), *PIK3CA/GATA3/MAP3K1/CBFB* (LumA).

Quais genes estão mais associados a pior prognóstico? Consistentes em Cox univariado, Cox ajustado e seleção estável por LASSO: **GSK3B** (HR 1,23 bruto; 1,13 ajustado; selecionado em 72% das repetições), **AURKA** (1,19 bruto; 1,46 para mortalidade específica), **VEGFA** (1,17; 1,13 ajustado), *FANCD2*, *E2F7*, *E2F2*, *CCNE1*. Como marcadores de **melhor** prognóstico: **STAT5A** (HR 0,81; selecionado em 60% das repetições), *SPRY2*, *IGF1*, *ABCB1*, *BCL2*, *STAT5B*, *PDGFRA*, *CDKN2C*.

Com que grau de confiança? Alta para a existência das associações (FDR rigoroso, n = 1.897, efeitos replicados entre OS e DSS e entre métodos independentes). **Baixa** para a utilidade preditiva incremental: nenhuma combinação desses genes superou, fora da amostra, um modelo clínico simples baseado em idade, grau, tamanho, linfonodos e subtipo.

7. Limitações

1. **Cobertura gênica parcial.** Foram analisados 489 genes de um painel curado, não o transcriptoma completo (~24.000 genes) do METABRIC — este está disponível no cBioPortal apenas via Git LFS/S3, fora do alcance da rede deste ambiente. Genes prognósticos fora do painel não podem ser detectados, e as análises de enriquecimento de vias ficam enviesadas pela composição do painel.
2. **Pressuposto de riscos proporcionais violado** em 12 dos 20 genes mais fortes; os HR representam efeitos médios no seguimento.
3. **Ausência de validação externa independente.** Toda a validação foi interna (partições repetidas). Confirmação em TCGA-BRCA, GSE ou coorte própria é o passo seguinte obrigatório.
4. **Confundimento por tratamento.** A coorte é histórica (pré-trastuzumabe, esquemas adjuvantes heterogêneos); prognóstico e resposta terapêutica não são separáveis aqui.
5. **Dicotomização pela mediana** nas curvas KM tem finalidade descritiva; a inferência formal usa a expressão contínua.
6. **Mortalidade competitiva.** A OS inclui 480 óbitos por outras causas em uma coorte de mediana etária elevada; a análise de DSS mitiga, mas o tratamento formal exigiria modelos de risco competitivo (Fine-Gray).
7. **Grupo “Normal-like”** provavelmente reflete contaminação por tecido normal (80,7% de erro de classificação), e resultados nesse estrato devem ser interpretados com cautela.
8. **z-scores calculados sobre a coorte inteira** implicam que os valores de cada amostra dependem da composição do estudo, limitando a aplicação direta do escore a um paciente individual sem recalibração.

8. Dicionário completo das saídas geradas

8.1 Tabelas (saídas/tabelas/ , 33 arquivos CSV)

Arquivo	Conteúdo
T01_integridade_dados	Verificações de integridade e checksum MD5 do arquivo de origem
T02_auditoria_codificacao_evento	Tabulação cruzada que define a codificação do evento de óbito
T03_fluxograma_exclusoes	Fluxograma de exclusões com n em cada etapa
T04_qc_expressao_por_gene	Média, DP, MAD, mínimo e máximo dos 489 genes
T05_caracteristicas_clinicas_por_subtipo	17 variáveis clínicas resumidas por subtipo
T06_testes_associacao_clinica_subtipo	Qui-quadrado e Kruskal-Wallis com FDR
T07_expressao_diferencial_completa_todos_subtipos	2.934 linhas — resultado completo do limma (489 genes × 6 subtipos)
T08_resumo_expressao_diferencial	Contagem de genes significativos por subtipo
T09_top15_genes_por_subtipo	15 genes de maior efeito em cada subtipo
T10_randomforest_matriz_confusao	Matriz de confusão out-of-bag e erro por classe
T11_randomforest_importancia_genes	Ranking completo dos 489 genes por importância
T12_cox_univariado_OS_todos_genes	Cox de sobrevida global para os 489 genes (HR, IC 95%, p, FDR, concordância)
T13_cox_univariado_DSS_todos_genes	Idem para sobrevida específica do câncer
T14_teste_riscos_proporcionais_top20	Teste <code>cox.zph</code> dos 20 genes mais prognósticos
T15_cox_multivariado_ajustado_top20	Cox ajustado por 8 covariáveis clínicas
T16_mediana_sobrevida_por_subtipo	Medianas de OS com IC 95%
T17_logrank_top4_genes	Log-rank dos 4 genes principais dicotomizados
T18_cox_estratificado_por_subtipo	12 genes × 6 subtipos: HR e p dentro de cada estrato
T19_assinatura_lasso_cox_coeficientes	65 genes e coeficientes em <code>lambda.min</code>
T19b_assinatura_lasso_lambda1se	12 genes da assinatura parcimoniosa
T20_desempenho_modelos_C_index	C-index dos 5 modelos em partição única
T21_teste_razao_verossimilhanca	LRT clínico vs. clínico+assinatura
T22_grupos_de_risco_por_conjunto	Distribuição de óbitos por tercil de risco
T23_mutacoes_por_subtipo	Frequência mutacional de 71 genes por subtipo, Fisher + FDR
T24_cox_mutacoes_OS	Cox de sobrevida para cada gene mutado
T25_integracao_subtipo_prognostico	223 pares gene-subtipo com HR, coerência direcional e anotações
T26_genes_prioritarios_por_subtipo	Top 10 por subtipo pelo escore de prioridade
T27_resumo_execucao	Metadados e métricas-chave da execução
T28_bibliotecas_versoes	22 pacotes com versão exata
T29_validacao_repetida_25_particoes	C-index das 3 abordagens em cada uma das 25 repetições
T30_resumo_validacao_repetida	Média, DP, mínimo e máximo do C-index
T31_comparacao_pareada_modelos	Testes de Wilcoxon pareados entre modelos
T32_estabilidade_selecao_lasso	Frequência de seleção de cada gene nas 25 repetições

8.2 Figuras (saidas/figuras/ , 13 arquivos PNG a 150-170 dpi)

Arquivo	Conteúdo
F01_distribuicao_subtipos	Distribuição dos subtipos e mortalidade bruta
F02_volcano_por_subtipo	Seis volcano plots com genes rotulados
F03_heatmap_genes_discriminantes	Heatmap com clusterização dos genes mais discriminantes
F04_importancia_randomforest	Top 30 genes por importância no Random Forest
F05_forest_cox_univariado_OS	Forest plot dos 25 genes mais prognósticos
F06_km_subtipos	Kaplan-Meier por subtipo com tabela de risco
F07_km_top4_genes	Kaplan-Meier dos 4 genes principais
F08_heatmap_cox_estratificado	HR por gene dentro de cada subtipo
F09_km_grupos_risco_validacao	Validação independente dos tercís de risco
F10_coeficientes_assinatura_lasso	Coeficientes dos 65 genes da assinatura
F11_mutacoes_por_subtipo	Frequência mutacional por subtipo
F12_integracao_subtipo_prognostico	Δz vs. $\log_2(\text{HR})$ por subtipo
F13_estabilidade_validacao_repetida	Distribuição do C-index e estabilidade de seleção

8.3 Demais artefatos

- `metabRIC_pipeline.R` — script único, 764 linhas, comentado, executável de ponta a ponta
- `saidas/objetos_analise.rds` — todos os objetos da análise para reanálise sem reexecutar
- `saidas/logs/execucao.log` — log completo com marcação de tempo por módulo
- `saidas/logs/sessionInfo.txt` — ambiente exato para reprodução

9. Como reproduzir

O script é **autossuficiente**: não exige edição de caminhos, instalação prévia de pacotes nem download manual de dados. Em qualquer computador com R ≥ 4.0 (Linux, macOS ou Windows):

```
Rscript metabRIC_pipeline.R
```

O que ele faz sozinho, nesta ordem:

1. **Detecta o próprio diretório** (via `--file=` do Rscript, via `ofile` quando usado com `source()`, ou o diretório atual em sessão interativa) e cria a estrutura `dados/` e `saidas/{tabelas, figuras, logs}`.
2. **Configura o locale UTF-8** testando os nomes usados em Linux, macOS e Windows — sem isso os acentos quebram a renderização das figuras do `survminer`.
3. **Instala as dependências ausentes**: 21 pacotes do CRAN (<https://cloud.r-project.org>) e o `limma` via `BiocManager`. Pacotes já presentes são preservados. Se a instalação falhar, a mensagem de erro sugere o comando `apt-get` equivalente para Debian/Ubuntu, que evita compilação.
4. **Baixa o arquivo de entrada** (`METABRIC_RNA_Mutation.csv`, 8,1 MB) de `raw.githubusercontent.com` e **verifica o MD5** contra a referência `c619471beb87af0f9fd4e4a40058654d`. O resultado da verificação e a URL efetivamente usada ficam registrados em `T01_integridade_dados.csv`.
5. **Executa toda a análise** e grava 33 tabelas, 13 figuras, os logs e o `.rds` com os objetos.

Comportamento em execuções repetidas e em falhas — testado explicitamente:

Situação	Comportamento verificado
Diretório limpo, só com o script	Baixa os dados e executa do início ao fim
Arquivo já presente e íntegro	Confirma o MD5 e pula o download
Arquivo local corrompido ou truncado	Detecta pela validação estrutural, descarta e rebaixa
MD5 divergente mas estrutura válida	Emite aviso e prossegue (tolera atualização do espelho)
Todas as fontes indisponíveis	Falha com instrução explícita de download manual e o caminho exato de destino
Sem rede, arquivo posto manualmente em <code>dados/</code>	Valida e executa normalmente, sem tentar baixar

Variáveis de ambiente opcionais:

```
METABRIC_DIR=/caminho/alternativo Rscript metabRIC_pipeline.R # outro diretório de trabalho
METABRIC_NREP=3 Rscript metabRIC_pipeline.R # teste rápido (~2,6 min)
```

Tempo de execução: ~6,6 min com o padrão de 25 repetições, em 1 vCPU e 3 GB de RAM. O Módulo 8b responde por cerca de 4,7 min desse total; com `METABRIC_NREP=3` a execução completa cai para ~2,6 min (útil para validar o ambiente antes da rodada definitiva). Todas as etapas com aleatoriedade — Random Forest, validação cruzada do LASSO e partições — usam sementes fixas, de modo que os números deste relatório são reproduzidos bit a bit.

Validação estrutural do arquivo baixado. Antes de qualquer análise, o script confere a presença das colunas críticas (`patient_id`, `pam50+_claudin-low_subtype`, `overall_survival`, `overall_survival_months`, `death_from_cancer`, `tp53`, `erbb2`), o número mínimo de colunas e o tamanho do arquivo — o que evita que uma página de erro HTML salva como CSV seja processada silenciosamente como se fossem dados.

10. Próximos passos sugeridos

1. **Obter a matriz de expressão completa** (~24.000 genes) do cBioPortal em rede sem restrição, repetindo os Módulos 4, 6 e 8 — a cobertura atual de 489 genes é a limitação mais séria.
 2. **Modelagem tempo-dependente** (`tt()` no `coxph` ou modelos de tempo de falha acelerado) para os 12 genes que violam riscos proporcionais.
 3. **Restringir o escopo aos tumores luminais**, onde toda a informação prognóstica transcricional se concentra (seção 5.7), e rederivar a assinatura nesse contexto — é a hipótese mais promissora para superar o modelo clínico.
 4. **Validação externa** em TCGA-BRCA, com atenção à diferença de plataforma (microarranjo vs. RNA-seq).
 5. **Análise de enriquecimento funcional** dos 125 genes prognósticos, com correção pelo viés de composição do painel.
 6. **Modelos de risco competitivo** (Fine-Gray) dada a alta proporção de óbitos por outras causas.
-

11. Referências

- Curtis C, Shah SP, Chin SF, et al. The genomic and transcriptomic architecture of 2,000 breast tumours reveals novel subgroups. *Nature*. 2012;486(7403):346-352.
- Pereira B, Chin SF, Rueda OM, et al. The somatic mutation profiles of 2,433 breast cancers refine their genomic and transcriptomic landscapes. *Nat Commun*. 2016;7:11479.
- Ritchie ME, Phipson B, Wu D, et al. limma powers differential expression analyses for RNA-sequencing and microarray studies. *Nucleic Acids Res*. 2015;43(7):e47.
- Simon N, Friedman J, Hastie T, Tibshirani R. Regularization paths for Cox's proportional hazards model via coordinate descent. *J Stat Softw*. 2011;39(5):1-13.
- Benjamini Y, Hochberg Y. Controlling the false discovery rate. *J R Stat Soc B*. 1995;57(1):289-300.
- Therneau TM, Grambsch PM. *Modeling Survival Data: Extending the Cox Model*. Springer; 2000.
- Meinshausen N, Bühlmann P. Stability selection. *J R Stat Soc B*. 2010;72(4):417-473.